

석 사 학 위 논 문

양팔 협동 조작에서 내부 힘 억제를 위한
모방학습 최적화

허의찬

부산대학교 대학원
전기전자공학과

2026년 8월

양팔 협동 조작에서 내부 힘 억제를 위한 모방학습 최적화

이 논문을 공학석사 학위논문으로 제출함

허의찬

부산대학교 대학원

전기전자공학과

지도교수 이인호

허의찬의 공학석사 학위논문을 인준함

2026년 06월 15일

위원장	서정원	인
-----	-----	---

위원	이인호	인
----	-----	---

위원	정우성	인
----	-----	---

차 례

<제목 차례>

1. INTRODUCTION	1
1.1. Background	1
1.2. Problem Definition	4
1.3. Research Objectives	7
1.4. Research Contribution	8
1.5. Thesis Organization	10
2. RELATED WORK	12
2.1. Behavior Cloning for Robotic Manipulation	12
2.2. Force-aware Imitation Learning for Bimanual Manipulation	14
2.3. Differentiable Optimization for Imitation Learning	16
3. Preliminaries	19
3.1. Action Chunking with Transformer	19
3.2. Control Barrier Function as a Safety Constraint	24
4. Proposed Work	29
4.1. Overview of the Proposed Framework	29
4.2. Stage 1: Pre-training of Nominal Imitation Policy	31
4.3. Stage 2: Pre-training the Delta Wrench Predictor	33
4.4. Stage 3: Fine-tuning and Inference with Res-IL	35
5. Experiments	40
5.1. Experimental Settings	40
5.2. Simulation-based Evaluation	47
5.3. Real-World Hardware-based Evaluation	54
6. Conclusion and Future Work	58
6.1. Conclusion	58
6.2. Limitation and Future Work	61
참고문헌	65
7. Appendix	73
Abstract	76

<표 차례>

[Table 1] Simulation and Contact Parameters used in Experiments	41
[Table 2] Specification of Franka Research 3	45
[Table 3] Specification of Intel Realsense D435	46
[Table 4] Comparison between ACT baseline and Proposed Res-IL (Simulation)	50
[Table 5] Comparison between Res-IL w/o and w/ CBF (Simulation)	53
[Table 6] Nominal Imitation Policy (ACT) Hyper Parameters	73
[Table 7] Delta Wrench Predictor Hyper Parameters	74
[Table 8] Res-IL Hyper Parameters	75

<그림 차례>

[Fig 1] Bimanual Robot Platforms	2
[Fig 2] Bimanual Manipulation Tasks	4
[Fig 3] Internal Force Exists in Cooperative Manipulation	6
[Fig 4] Overview of Behavior Cloning Process for Robotic Manipulation	14
[Fig 5] Architecture of Action Chunking with Transformer (ACT)	24
[Fig 6] Overview of the Res-IL Architecture	29
[Fig 7] Pre-training Nominal Imitation Policy	31
[Fig 8] Pre-training Delta Wrench Predictor	33
[Fig 9] Fine-tuning and Inference with Res-IL	35
[Fig 10] Overall Architecture of the Proposed Res-IL Framework	39
[Fig 11] MuJoCo Environment for Simulation Experiment	40
[Fig 12] Real-world Environment for Hardware Experiment	43
[Fig 13] Franka Research 3 used in this Research	44
[Fig 14] Intel Realsense D435	46
[Fig 15] Qualitative Comparison of ACT baseline (Top) and Fine-tuned Res-IL (Bottom) in Simulation	49
[Fig 16] Internal-Force Proxy Comparison between ACT only and Fine-tuned Res-IL in Simulation	50
[Fig 17] Qualitative Comparison of Res-IL without CBF (Top) and Res-IL with CBF (Bottom) in Simulation	52

[Fig 18] Internal-Force Proxy Comparison between Res-IL w/o CBF and Res-IL w/ CBF in Simulation	53
[Fig 19] Qualitative Comparison of ACT baseline (Left) and Fine-tuned Res-IL (Right) in Real-world Experiment	56

양팔 협동 조작에서 내부 힘 억제를 위한 모방학습 최적화

허의찬

부산대학교 대학원 전기전자공학과

요약

최근 모방학습 기반 로봇 조작은 시각·고유감각 정보로 복잡한 조작 행동을 학습하도록 발전해왔다. 특히 Transformer 기반 정책은 양팔 로봇 조작에서 시연 데이터를 효과적으로 모방하여 안정적인 동작을 생성한다. 그러나 기존 모방학습 정책은 주로 시연 궤적 재현에 초점을 맞추기 때문에, 두 로봇 팔이 동일 물체를 동시에 조작하는 협동 양팔 상황에서 발생하는 물리적 상호작용 힘을 명시적으로 고려하지 못한다. 물체를 통해 두 팔이 연결된 closed-chain 상황에서는 물체의 운동에는 기여하지 않지만 조작 안정성을 저하시켜 구동기 부하를 증가시키는 내부 힘이 발생할 수 있다. 본 연구는 이러한 문제를 해결하기 위해, 작업 수행 능력을 유지하면서 내부 힘을 저감하는 Residual QP-based Imitation Learning(Res-IL) 프레임워크를 제안한다.

Res-IL의 성능은 MuJoCo 기반 시뮬레이션 및 실제 하드웨어 실험을 통해 검증하였다. 실험에서는 두 로봇 팔이 동일 강체 물체를 파지하고 들어 올리는 과정에서 발생하는 손목 힘/토크를 기준으로 기존 Action Chunking with Transformer(ACT)와 제안 방법을 비교하였다. 그 결과, 시뮬레이션 상에서 Res-IL은 기존 정책과 유사한 작업 성공률을 유지하면서도 internal-force proxy를 줄였으며, 평균 force norm과 torque norm을 각각 39.0%, 25.1% 감소시켰다. 또한 CBF(Control Barrier Function) 제약을 적용한 경우, CBF를 미적용한 경우보다 최대 힘/토크 크기와 분산이 감소하여 보다 안정적인 접촉 조작이 가능함을 보였다. 이러한 결과는 협동 양팔 조작에서 내부 힘 조절을 모방학습 정책에 명시적으로 통합하는 것이 물리적으로 일관된 양팔 조작에 중요함을 보여준다. 나아가 제안한 residual QP 구조는 내부 힘 최소화뿐만 아니라, 핸들 또는 밸브 회전과 같이 특정 힘/토크 프로파일을 요구하는 작업으로도 확장될 수 있으며, 이를 통해 힘 정보를 이용한 profile-following 기반 협동 조작으로 발전할 수 있다.

1. INTRODUCTION

1.1. Background

최근 로봇 조작 분야에서는 사람이 직접 설계한 제어 규칙에 의존하기보다, 인간의 시연 데이터를 바탕으로 로봇이 작업 수행 방법을 학습하는 모방학습(imitation learning) 기반 접근이 활발히 연구되고 있다 [7], [8]. 모방학습은 복잡한 조작 작업에서 명시적인 보상 함수나 세밀한 동역학 모델을 설계하지 않아도 된다는 장점이 있으며, 카메라 영상, 로봇 관절 상태, 말단 장치(end-effector) 자세 등 다양한 관측 정보를 입력으로 받아 작업에 필요한 행동을 직접 예측할 수 있다 [10], [12]. 특히 최근에는 Transformer 구조를 기반으로 한 시각-행동 정책(visuomotor policy) [1], [11], [14], 그리고 대규모 시각-언어-행동 모델(Vision-Language-Action model, VLA model) [24], [27]-[29] 등이 제안되면서 로봇 조작 정책의 표현 능력과 일반화 가능성이 크게 향상되고 있다.

그러나 실제 로봇 조작 상황에서는 단순히 물체의 위치를 인식하고 목표 위치로 이동하는 것만으로 충분하지 않다. 로봇은 작업 수행 중 물체 및 환경과 지속적으로 접촉하며, 이러한 접촉 과정에서 발생하는 힘과 토크는 작업 성공 여부와 조작 안정성에 직접적인 영향을 미친다 [37]-[45]. 특히 [Fig 1]과 같이 양팔 로봇을 이용한 협동 조작(cooperative bimanual manipulation)에서는 두 로봇 팔이 하나의 물체를 동시에 파지하고 조작하기 때문에, 두 팔의 움직임과 접촉 힘이 물체를 매개로 강하게 결합된다

[5], [6], [46], [47]. 이와 같은 상황에서는 로봇의 한쪽 팔에서 발생한 작은 위치 오차나 힘 불일치가 물체를 통해 다른 팔로 전달될 수 있으며, 결과적으로 전체 시스템의 조작 안정성을 저하시킬 수 있다 [46], [47].



(a) RB-Y1



(b) Atlas



(c) Optimus Gen 2



(d) YuMi - IRB 14000



(e) Franka Research 3 DUO

[Fig 1] Bimanual Robot Platforms

협동 양팔 조작의 대표적인 예로는, [Fig 2]와 같이 두 팔을 이용해 상자를 들어 올리는 작업, 양손으로 물체를 고정한 상태에서 삽입하거나 조립하는 작업, 또는 하나의 도구나 물체를 양팔이 동시에 지지하며 이동시키는 작업 등이 있다 [1], [5], [6]. 이러한 작업에서는 두 팔이 동일한 물체를 동시에 구속하기 때문에 로봇-물체-로봇 사이에 폐쇄-체인(closed-chain)이 형성된다 [46], [47]. 폐쇄-체인 조건에서는 물체의 강제 운동

에 직접적으로 기여하지 않으면서도 두 팔 사이에 작용하는 내부 힘(internal force)이 발생할 수 있다 [46]. 내부 힘은 물체를 원하는 방향으로 이동시키는 데 필요한 외력과 달리, 주로 두 로봇 팔 사이의 힘 불균형이나 상호 구속으로 인해 발생하는 힘이다 [46], [47]. 이러한 힘은 물체의 운동에는 기여하지 않지만, 접촉 안정성을 저하시킬 수 있고, 그리퍼 미끄러짐, 불안정한 파지, 구동기 부하 증가, 장기적인 하드웨어 손상 가능성을 유발할 수 있다 [37], [41], [46], [47].

기존의 모방학습 기반 조작 정책은 주로 시연된 동작 궤적을 재현하는 데 초점을 맞춘다 [7], [8], [10]. 즉, 정책은 주어진 관측으로부터 사람 또는 전문가가 수행한 행동을 최대한 정확하게 예측하도록 학습된다 [1], [4], [10], [12]. 이러한 접근은 pick-and-place와 같이 접촉 상호작용이 비교적 단순한 작업에서는 효과적으로 동작할 수 있다 [1], [12]. 그러나 협동 양팔 조작과 같이 두 팔 사이의 물리적 상호작용이 중요한 작업에서는, 단순한 궤적 재현만으로는 충분한 안정성을 보장하기 어렵다 [5], [26], [37], [46]. 사람이 제공한 시연 데이터는 작업 수행에 대한 성공을 중심으로 수집되는 경우가 많으며, 내부 힘을 최소화하는 방향으로 최적화되어 있지 않을 수 있다 [46], [47]. 따라서 모방학습 정책이 시연 궤적을 정확히 따라가더라도, 실행 과정에서 두 팔의 미세한 불일치가 누적되어 불필요한 내부 힘을 발생시킬 수 있다 [37], [46], [47].



(a) Box Lifting Task



(b) Drilling Task

[Fig 2] Bimanual Manipulation Tasks

1.2. Problem Definition


협동 양팔 조작에서 중요한 문제는 작업 수행을 위한 동작과 물리적으로 일관된 힘 조절을 동시에 만족해야 한다는 점이다 [46], [47]. [Fig 3]와 같이 두 팔이 동일한 물체를 파지하고 있는 상황에서 한쪽 팔의 움직임은 독립적으로 작용하지 않고, 물체를 통해 다른 팔에 직접적인 영향을 미친다 [5], [6], [46]. 따라서 각 팔이 개별적으로는 타당한 동작을 수행하더라도, 두 팔의 조합이 물체 수준에서 물리적으로 일관되지 않으면 내부 힘이 발생할 수 있다 [46], [47].

이러한 내부 힘은 시각 정보나 고유감각 정보만으로 완전히 예측하기 어렵다 [37]-[45]. 내부 힘의 크기와 방향은 물체와 그리퍼 사이의 접촉 위치, 마찰 조건, 파지 자세, 물체의 질량 및 관성, 로봇의 순응성, 그리고 양팔의 상대적인 움직임에 의해 결정된다 [41], [46], [47]. 특히 폐쇄-체인 조작에서는 작은 위치 오차도 큰 접촉 힘으로 증폭될 수 있기에, 정책이 생성한 동작이 시각적으로는 적절해 보이더라도 실제 접촉 상황에서

는 불안정한 힘 분포를 유발할 수 있다 [37], [46], [47].

기존 연구에서는 이러한 문제를 해결하기 위해 힘/토크 센서 정보를 정책 입력에 추가하거나, 임피던스 제어 및 하이브리드 위치/힘 제어를 결합하는 방식이 제안되어 왔다 [14]-[19], [37]-[45]. 이러한 접근은 접촉 작업에서 순응성을 높이고 외부 환경과의 상호작용을 안정화하는 데 도움을 줄 수 있다 [14], [15], [37], [41]. 그러나 단순히 힘 정보를 관측으로 추가하는 것만으로는 정책이 해당 힘을 어떻게 줄여야 하는지 명시적으로 학습하기 어렵다 [37], [42], [45]. 또한 각 팔을 개별적으로 순응적으로 제어하는 방식은 외부 환경과의 충격을 줄이는 데 효과적일 수 있지만, 두 팔 사이의 폐쇄-체인 결합으로 인해 발생하는 내부 힘 자체를 직접적으로 최소화한다고 보기는 어렵다 [46], [47].

따라서 협동 양팔 조작을 위한 모방학습 정책은 단순한 동작 모방을 넘어, 실행 중 발생하는 물리적 상호작용 힘을 명시적으로 고려할 필요가 있다 [37], [38], [46], [47]. 특히 본 연구에서는 물체의 운동에는 기여하지 않지만 조작 안정성을 저하시키는 내부 힘에 주목한다 [46], [47]. 목표는 기존 모방학습 정책이 학습한 작업 수행 능력을 유지하면서, 폐쇄-체인 접촉 이후 발생하는 불필요한 내부 힘을 줄이는 것이다 [1], [14], [46], [47]. 이를 위해서는 학습 기반 정책의 표현 능력과 최적화 기반 제어의 물리적 제약 처리 능력을 결합하는 구조가 필요하다.



[Fig 3] Internal Force Exists in Cooperative Manipulation

1.3. Research Objectives

본 연구의 목적은 협동 양팔 조작에서 모방학습 정책이 생성하는 작업 동작을 유지하면서, 폐쇄-체인 조건에서 발생하는 내부 힘을 명시적으로 저감하는 force-consistent imitation learning framework를 제안하는 것이다. 이를 위해 본 연구에서는 기존 ACT [1] 기반 모방학습 정책을 nominal imitation policy로 사용하고, 해당 정책이 예측한 행동에 대해 residual quadratic programming(residual QP) 기반 보정 행동을 추가하는 Residual QP-based Imitation Learning, 즉 Res-IL 구조를 제안한다.

제안하는 방법은 nominal imitation policy가 예측한 행동을 완전히 대체하지 않는다. 대신, 정책이 생성한 행동 주변에서 최소한의 residual action을 계산하여 작업에 필요한 동작은 유지하되, 손목 힘/토크 센서로 측정되는 내부 힘 proxy를 줄이는 방향으로 행동을 보정한다. 이러한 residual 구조는 모방학습 정책의 장점인 복잡한 시각-행동 패턴 학습 능력을 유지하면서도, 접촉 이후 발생하는 물리적 불일치를 최적화 문제로 직접 다룰 수 있게 한다.

또한 본 연구에서는 residual QP를 단순히 추론 시점에만 적용하지 않고, 정책 fine-tuning 과정에도 통합한다. 만약 QP 보정이 추론 시점에만 적용된다면, 학습 중 정책이 경험한 행동 분포와 실제 실행 시 사용되는 보정 행동 분포 사이에 불일치가 발생할 수 있다. 협동 양팔 조작에서는 작은 행동 변화도 접촉 조건과 힘 분포를 크게 바꿀 수 있으므로, 이러한 training-validation mismatch는 조작 안정성에 중요한 영향

을 줄 수 있다. 따라서 본 연구에서는 QP로 보정된 행동을 다시 정책이 회귀하도록 학습함으로써, 정책 자체가 force-aware action distribution에 점진적으로 적응하도록 한다.

마지막으로, residual QP가 내부 힘을 줄이는 과정에서 과도한 보정 행동을 생성하거나 로봇을 기구학적으로 불리한 자세로 유도하지 않도록 Control Barrier Function(CBF) 기반 제약을 함께 적용한다. 이를 통해 내부 힘 저감뿐만 아니라 조작 중의 기구학적 가능성과 안정성도 함께 고려한다.

1.4. Research Contribution

본 연구의 주요 내용과 기여는 다음과 같다.

첫째, 협동 양팔 모방학습에서 폐쇄-체인 결합으로 인해 발생하는 내부 힘 문제를 정의한다. 기존 모방학습 기반 로봇 조작 정책은 주로 시연된 동작 궤적을 재현하는 데 초점을 맞추기 때문에, 두 로봇 팔이 동일한 물체를 동시에 조작하는 협동 양팔 조작 상황에서 발생하는 물리적 힘 불일치를 명시적으로 고려하지 못한다. 특히 두 팔과 물체가 폐쇄-체인을 형성하는 경우, 물체의 운동에는 기여하지 않지만 조작 안정성을 저하시킬 수 있는 내부 힘이 발생할 수 있다. 본 연구는 이러한 내부 힘을 협동 양팔 모방학습의 주요 한계로 정의하고, 단순한 동작 모방만으로는 안정적인 접촉 기반 협동 조작을 달성하기 어렵다는 점을 제시한다.

둘째, 작업 동작을 보존하면서 내부 힘을 줄이기 위한 residual QP 기반 행동 보정 방법론을 제안한다. 제안하는 방법은 nominal imitation policy가 예측한 행동을 직접 대체하지 않고, 해당 행동 주변에서 최소한의 residual action을 계산한다. 이를 위해 손목 힘/토크 피드백으로부터 정의한 internal-force proxy를 줄이는 residual QP를 구성한다. 또한 실제 접촉 동역학을 해석적으로 모델링하기 어렵다는 점을 고려하여, 최근 관측 이력과 행동 변화량으로부터 다음 시점의 내부 힘 변화를 예측하는 delta wrench predictor를 학습한다. 이 예측 모델은 residual QP가 보정 행동이 내부 힘에 미치는 영향을 근사적으로 평가할 수 있도록 하며, CBF 기반 안전 제약을 함께 적용하여 내부 힘 저감 과정에서 발생할 수 있는 기구학적 불안정성을 완화한다.

셋째, Residual QP 보정을 Policy fine-tuning 과정에 통합하는 force-consistent imitation learning 프레임워크를 제안한다. QP 보정을 추론 단계에만 적용할 경우, 학습 과정에서 정책이 따르던 행동 분포와 실제 실행 단계에서 사용되는 보정 행동 분포 사이에 차이가 발생할 수 있다. 이러한 분포 차이는 정책이 학습하지 못한 행동 영역에서 동작하게 만드는 Out-of-Distribution(OOD) 문제로 이어질 수 있다. 본 연구에서는 이를 완화하기 위해 fine-tuning 과정에서 QP-corrected action을 정책이 다시 회귀하도록 학습한다. 이를 통해 정책은 단순히 시연 행동을 모방하는 데 그치지 않고, 내부 힘을 고려한 보정 행동 분포에 점진적으로 적응하게 된다. 결과적으로 제안한 방법은 학습과 실행 사이의 불일치를 줄이며, 협동 양팔 조작에서 작업 수행 능력을 유지하면서도

보다 안정적이고 물리적으로 일관된 조작을 가능하게 한다.

1.5. Thesis Organization

본 논문의 구성은 다음과 같다. 제1장에서는 협동 양팔 조작에서 발생하는 내부 힘 문제와 기존 모방학습 기반 접근의 한계를 설명하고, 본 연구의 문제 정의, 연구 목적, 그리고 주요 기여를 제시한다. 제2장에서는 본 연구와 관련된 선행 연구를 정리한다. 구체적으로 모방학습 기반 로봇 조작, 힘 정보를 활용한 양팔 조작 학습, 그리고 협동 조작을 위한 미분 가능 최적화 기반 접근을 중심으로 기존 연구의 흐름과 한계를 살펴본다. 제3장에서는 제안 방법을 이해하기 위한 이론적 배경을 설명한다. 먼저 본 연구의 nominal policy로 사용되는 Action Chunking Transformer(ACT)의 구조와 특징을 정리하고, 이어서 residual action 최적화를 위한 Quadratic Programming(QP)과 안전 제약으로 활용되는 Control Barrier Function(CBF)의 기본 개념을 설명한다. 제4장에서는 본 연구에서 제안하는 Residual QP-based Imitation Learning(Res-IL) 프레임워크를 설명한다. 구체적으로 전체 구조를 개괄한 뒤, nominal imitation policy의 사전 학습, delta wrench predictor의 사전 학습, 그리고 residual QP를 이용한 fine-tuning 및 inference 과정을 단계별로 기술한다. 제5장에서는 제안 방법의 성능을 검증하기 위한 실험 설정과 결과를 제시한다. 먼저 전체 실험 환경과 평가 지표를 설명하고, MuJoCo 기반 시뮬레이션 실험을 통해 ACT baseline과 제안 방법의 성능을 비

교·분석하고, 실제 하드웨어 기반 실험을 통해 제안하는 방법의 실효성을 정성적으로 보인다. 마지막으로 제6장에서는 본 연구의 결론을 정리하고, 제안 방법의 한계와 향후 연구 방향을 논의한다. 특히 실제 로봇 환경에서의 force/torque sensor noise, 다양한 접촉 조건 및 물체 특성에 대한 일반화, 그리고 보다 안정적인 force-consistent imitation learning으로의 확장 가능성을 제시한다.

2. RELATED WORK

2.1. Behavior Cloning for Robotic Manipulation


최근 행동 복제(behavior cloning, BC)를 기반으로 한 로봇 모방학습 연구는 큰 발전을 이루어 왔으며 [7], [8], [10], 특히 Transformer 기반 생성 모델은 사전에 수집된 시연 데이터를 충실히 재현함으로써 로봇 조작 정책의 성능을 크게 향상시켰다 [1], [11], [12], [14]. [Fig 4]는 이러한 행동 복제 기반 모방학습의 일반적인 절차를 나타낸다. 먼저 인간 시연을 통해 로봇 관절 상태, 말단 장치 자세, 카메라 영상 등의 데이터를 수집하고, 수집된 데이터를 이용해 정책 모델을 학습한 뒤, 학습된 모델을 실제 로봇에 적용하여 실시간으로 행동을 추론하고 작업을 수행한다. 그러나 이러한 행동 복제 기반 접근을 양팔 조작으로 확장하는 데에는 여전히 여러 어려움이 존재한다 [4]-[6], [25]-[30]. 양팔 조작은 단일 팔 조작에 비해 행동 공간의 차원이 높고, 두 팔이 시간적·공간적으로 조화를 이루는 시연 데이터를 수집해야 하므로 데이터 수집 비용이 증가한다 [1], [2], [4], [6]. 이러한 특성은 학습 정책의 확장성과 일반화 성능을 제한하는 요인으로 작용한다 [1], [5], [25], [26].

최근 연구들은 이러한 문제를 완화하기 위해 다양한 접근을 제안하였다. 예를 들어, 단일 팔 조작에서 학습한 skill component를 양팔 작업에 재사용하거나 [25], 두 팔에 비대칭적인 역할을 부여하여 협동 조작을 수행하는 방법 [4], [5], 또는 공유된 3차원 voxel 기반 장면 표현으로부터 양팔의 joint action sequence를 동시에 예측하는 통합

양팔 정책을 학습하는 방법 등이 제안되었다 [11], [23]. 이러한 연구들은 양팔 간의 조정 효율을 높이고, pick-and-place와 같은 위치 제어 기반 작업에서 높은 성공률을 달성하였다 [1], [2], [4], [5], [25].

그러나 기존 모방학습 기반 조작 정책은 주로 시연된 동작 궤적을 정확히 재현하는데 초점을 맞춘다 [7], [8], [10]. 즉, 정책은 관측으로부터 전문가의 행동을 예측하도록 학습되지만, 실행 중 발생하는 물리적 접촉 힘이나 두 로봇 팔 사이의 상호작용을 명시적으로 최적화하지는 않는다 [37]-[45]. 이러한 한계는 단일 로봇 팔이 물체를 집고 이동하는 단순한 작업에서는 크게 드러나지 않을 수 있지만, 두 로봇 팔이 동일한 물체를 동시에 파지하고 조작하는 협동 양팔 조작에서는 중요한 문제가 된다 [5], [6], [46], [47]. 협동 양팔 조작에서는 두 팔이 물체를 통해 기구학적·동역학적으로 연결되기 때문에, 각 팔의 동작이 개별적으로는 타당하더라도 두 팔 사이의 미세한 불일치가 내부 힘을 유발할 수 있다 [46], [47].

본 연구는 이러한 한계를 보완하기 위해 실시간 F/T 피드백을 활용하여 residual action을 생성하고, 접촉 상황에서 발생하는 내부 힘을 명시적으로 최소화하는 방법을 제안한다 [37], [38], [46], [47]. 이를 통해 기존 모방학습 정책이 가지는 동작 재현 능력을 유지하면서도 [1], [10], [12], 협동 양팔 조작에서 요구되는 물리적 일관성과 접촉 안정성을 향상시키고자 한다 [37], [41], [46], [47].



[Fig 4] Overview of Behavior Cloning Process for Robotic Manipulation

2.2. Force-aware Imitation Learning for Bimanual Manipulation

접촉이 중요한 로봇 조작 작업에서는 시각 정보와 고유감각 정보만으로는 안정적인 실행을 보장하기 어렵다 [37]-[45]. 물체를 밀거나, 삽입하거나, 양손으로 파지하는 작업에서는 로봇과 환경 사이의 상호작용 힘이 작업 성공 여부에 직접적인 영향을 미친다 [37], [39], [41], [43]-[45]. 이에 따라 최근 연구들은 F/T sensor, tactile sensor, 또는 추정된 external force를 모방학습 정책의 입력으로 활용하여 접촉 상황에서의 조작 안정성을 높이려고 하였다 [37]-[45].

일부 연구들은 힘 정보를 추가적인 observation으로 사용하여 기존의 vision-only policy보다 더 순응적이고 안정적인 접촉 행동을 생성하도록 하였다 [37]-[39], [43]-[45]. 또 다른 연구들은 visual feature와 force, 또는 tactile feature를

cross-attention 구조로 융합하거나, 접촉 상황에 따라 시각 정보와 촉각 정보의 중요도를 동적으로 조절하는 방식으로 force-aware policy를 구성하였다 [40], [42], [43]. 이러한 방법들은 접촉이 발생하는 순간에 물리적 상호작용 정보를 활용할 수 있다는 점에서 기존의 motion-centric imitation learning보다 발전된 형태라고 볼 수 있다 [37]-[45].

힘 정보를 제어 단계에서 활용하는 연구들 또한 존재한다. 예를 들어, 정책이 예측한 위치와 힘을 hybrid position/force control에 사용하거나, 접촉 방향에 따라 impedance stiffness를 조절하는 방식이 제안되었다 [14]-[19], [38], [41]. 이러한 접근은 외부 환경과의 접촉에서 충격을 줄이고, 특정 방향으로 순응적인 동작을 생성하는 데 효과적이다 [14], [15], [38], [41]. 즉, force-aware imitation learning은 접촉 조작에서 기존 behavior cloning의 한계를 완화하기 위한 중요한 연구 흐름이라고 할 수 있다 [37]-[45].

그러나 이러한 기존 연구들은 주로 로봇과 외부 환경 사이의 접촉 안정성을 높이거나, 개별 로봇 팔의 순응성을 향상시키는 데 초점을 둔다 [37]-[45]. 반면 협동 양팔 조작에서는 두 로봇 팔이 동일한 물체를 동시에 파지하고 조작하면서, 로봇-물체-로봇으로 이어지는 폐쇄-체인(closed-chain)을 형성한다 [46], [47]. 이 경우 조작 안정성은 각 팔이 외부 접촉에 얼마나 순응적으로 반응하는지 뿐만 아니라, 두 팔이 물체에 가하는 힘이 서로 물리적으로 일관된지를 함께 고려해야 한다 [46], [47]. 예를 들어 한쪽 팔에서

발생한 작은 위치 오차나 힘 불균형은 공유 물체를 통해 다른 팔로 전달될 수 있으며, 이 과정에서 물체의 운동에는 기여하지 않는 내부 힘이 발생할 수 있다 [46], [47].

따라서 단순히 힘 정보를 정책 입력에 추가하거나 각 팔을 개별적으로 compliant하게 제어하는 것만으로는 협동 양팔 조작에서 발생하는 내부 힘을 직접적으로 줄이기 어렵다 [38], [41], [46], [47]. 본 연구는 이러한 한계를 고려하여, 손목 F/T feedback을 단순 observation으로 사용하는 것이 아니라 residual QP의 최적화 신호로 활용한다 [46]-[48], [52]-[56]. 이를 통해 두 팔 사이의 force inconsistency를 명시적으로 줄이고, 작업 수행 동작을 유지하면서도 물리적으로 일관된 협동 조작을 가능하게 한다.

2.3. Differentiable Optimization for Imitation Learning

최근에는 학습 기반 정책과 최적화 기반 제어를 결합하려는 연구도 활발히 이루어지고 있다 [48]-[51], [55], [56]. 순수한 neural network policy는 복잡한 관측으로부터 행동을 직접 예측할 수 있다는 장점이 있지만, 안전 제약, 기구학적 한계, 동역학적 일관성 등을 명시적으로 보장하기 어렵다 [48], [52]-[56]. 반면, 최적화 기반 제어는 제약 조건을 수식으로 표현하고 이를 만족하는 행동을 계산할 수 있지만, 복잡한 시각 관측이나 다양한 시연 행동 분포를 직접 모델링하는 데 한계가 있다. 따라서 두 접근을 결합하는 differentiable optimization 또는 optimization-in-the-loop 방식은 로봇 조작에서 중요한 연구 방향으로 주목받고 있다 [48]-[51], [55], [56].

기존 연구들은 imitation policy 내부에 optimization layer를 삽입하거나, 별도의 differentiable optimization module을 사용하여 행동 sequence를 보정하는 방식을 제안하였다 [48]-[51]. 이러한 방법들은 정책이 생성한 행동을 부드럽게 만들거나, 기구학적 제한을 만족하도록 하거나, 시연 데이터 분포와의 차이를 줄이는 데 효과적이다 [49]-[51]. 특히 trajectory optimization 관점에서 policy output을 refinement하는 방식은 neural network policy의 표현 능력과 optimization의 제약 처리 능력을 동시에 활용할 수 있다는 장점을 가진다 [48]-[51].

하지만 기존 differentiable optimization 기반 연구들은 주로 trajectory smoothness, joint limit, kinematic bound, future action consistency와 같은 제약에 초점을 맞추는 경우가 많다 [49]-[51]. 이러한 제약들은 로봇 동작의 안정성과 실행 가능성을 높이는 데 중요하지만, 협동 양팔 조작에서 발생하는 내부 힘 문제를 직접적으로 다루지는 않는다. 특히 두 팔이 동일한 물체를 동시에 조작하는 폐쇄-체인 상황에서 단순히 궤적이 부드럽거나 기구학적 한계를 만족한다고 해서 내부 힘이 줄어드는 것은 아니다 [46], [47]. 두 팔의 상대적인 움직임과 접촉 힘이 물체를 통해 강하게 결합되기 때문에, force-level consistency를 별도로 고려할 필요가 있다 [46], [47].

본 연구는 이러한 기존 연구들과 달리, 최적화 기반 보정을 협동 양팔 조작의 내부 힘 저감 문제에 직접 적용한다. 제안하는 Res-IL은 nominal imitation policy가 예측한 행동 전체를 대체하지 않고, 해당 행동 주변에서 최소한의 보정 action을 계산한다. 이

를 통해 모방학습 정책이 학습한 작업 수행 능력은 유지하면서, 접촉 이후 발생하는 internal-force proxy를 줄일 수 있다. 또한 보정 과정에서 Control Barrier Function(CBF) 기반 제약을 함께 적용하여, 내부 힘을 줄이는 과정에서 로봇이 기구학적으로 불안정한 자세로 이동하는 것을 방지한다.

나아가 본 연구는 residual QP를 단순히 inference-time correction으로만 사용하지 않고, policy fine-tuning 과정에도 통합한다. 이를 통해 정책은 QP로 보정된 행동 분포를 다시 학습하게 되며, 학습 단계와 실행 단계 사이의 불일치를 줄일 수 있다. 이러한 구조는 학습 기반 정책의 표현 능력, force feedback 기반 물리적 보정, 그리고 최적화 기반 안전 제약을 결합한다는 점에서 기존 differentiable optimization 기반 조작 연구와 차별화된다.

3. Preliminaries

3.1. Action Chunking with Transformer

로봇 조작을 위한 모방학습은 전문가의 시연 데이터로부터 관측과 행동 사이의 매핑을 학습하는 방식이다. 일반적인 behavior cloning 정책은 현재 관측 o_t 가 주어졌을 때 단일 시점의 행동 a_t 를 예측하도록 학습된다. 그러나 로봇 조작 작업, 특히 양팔을 이용한 미세 조작이나 접촉이 많은 작업에서는 단일 행동 예측 방식이 여러 한계를 가진다. 첫째, 정책이 한 시점에서 작은 오차를 생성하면 이후 상태가 학습 데이터 분포에서 벗어날 수 있으며, 이러한 오차가 시간에 따라 누적되는 compounding error 문제가 발생한다. 둘째, 인간 시연 데이터에는 일시적인 정지, 속도 변화, 미세한 조정 동작과 같이 현재 상태만으로는 설명하기 어려운 시간적 상관성이 포함될 수 있다. 셋째, 고주파 제어가 요구되는 조작 작업에서는 매 시점 독립적으로 예측된 행동이 불연속적이거나 진동하는 형태로 나타날 수 있다.

Action Chunking with Transformers(ACT) [1]는 이러한 문제를 완화하기 위해 제안된 Transformer 기반 모방학습 정책이다. ACT의 핵심 아이디어는 현재 관측으로부터 단일 행동을 예측하는 것이 아니라, 앞으로 수행할 여러 시점의 행동을 하나의 action chunk로 예측하는 것이다. 즉, 일반적인 정책이 수식 (1)과 같이 현재 시점의 행동만을 예측한다면,

$$\pi_{\theta}(a_t|o_t) \quad (1)$$

ACT는 chunk size k 에 대응하여 다음 k 개 시점의 행동 sequence를 예측한다.

$$\pi_{\theta}(a_{t:t+k}|o_t) \quad (2)$$

이러한 action chunking 구조는 전체 작업의 유효 horizon을 줄이는 효과를 가진다.

예를 들어, 원래 T 개의 제어 step으로 구성된 작업에서 정책이 한 번에 k 개의 행동을

예측하면, 정책이 반복적으로 의사결정을 수행해야 하는 횟수는 상대적으로 줄어든다.

이는 작은 행동 오차가 매 시점 누적되는 문제를 완화하고, 장시간 조작 작업에서 더 안

정적인 행동 생성을 가능하게 한다. 또한 action chunk는 인간 시연에서 나타나는 일

정 구간의 연속적인 행동 패턴을 하나의 단위로 모델링할 수 있기 때문에, 단일 시점 정

책보다 non-Markovian property를 더 잘 표현할 수 있다.

ACT는 action chunk를 예측하기 위해 Conditional Variational Auto-encoder

(CVAE) 구조를 사용한다. 학습 시에는 demonstration action sequence와 현재 관측

을 입력으로 받아 latent variable z 를 추정하는 encoder와, 현재 관측 및 latent

variable을 조건으로 미래 action sequence를 생성하는 decoder로 구성된다.

Encoder는 다음과 같이 action chunk와 관측으로부터 latent distribution을 추정한다.

$$z \sim q_{\phi}(z|a_{t:t+k}, \bar{o}_t) \quad (3)$$

여기서 $\bar{o}_t$ 는 image observation을 제외한 proprioceptive observation을 의미한다.

Decoder는 현재 관측 o_t 와 latent variable z 를 입력으로 받아 미래 action chunk를 예측한다.

$$\pi_{\theta}(\hat{a}_{t:t+k}|o_t, z) \quad (4)$$

CVAE 구조를 사용하는 이유는, 인간 시연 데이터가 본질적으로 다중 모드적이고 확률적이기에 동일한 작업 상태에서도 사람은 여러 가능한 경로를 통해 목표를 달성할 수 있으며, 정밀도가 크게 중요하지 않은 구간에서는 행동의 변동성이 더 크게 나타날 수 있다. CVAE는 이러한 시연 데이터의 다양성을 latent variable z 로 표현함으로써, 단순한 deterministic regression보다 시연 행동 분포를 유연하게 모델링할 수 있다. 학습 과정에서는 예측된 action chunk와 실제 demonstration action chunk 사이의 reconstruction loss와, latent distribution을 Gaussian prior에 가깝게 만드는 KL divergence regularization을 함께 사용하는데, 이를 수식으로 나타내면 다음과 같다.

$$L_{ACT} = L_{recon} + \beta L_{KL} \quad (5)$$

$$L_{recon} = \|\hat{a}_{t:t+k} - a_{t:t+k}\| \quad (6)$$

$$L_{KL} = D_{KL}(q_{\phi}(z|a_{t:t+k}, \bar{o}_t) \| \mathcal{N}(0, I)) \quad (7)$$

여기서 β 는 KL regularization의 가중치를 조절하는 계수이다. 학습 시에는 CVAE encoder와 decoder를 함께 사용하지만, 추론 시에는 실제 action sequence를 알 수

없기 때문에 encoder는 사용하지 않는다. 대신 latent variable z 를 prior distribution의 평균값, 즉 $z=0$ 으로 설정하고, decoder policy만을 이용하여 현재 관측으로부터 action chunk를 예측한다.

ACT의 [Fig 5]과 같이 네트워크 구조는 Transformer encoder-decoder를 기반으로 한다. 먼저 다중 시점 RGB image는 CNN backbone을 통해 feature map으로 변환되고, 여기에 positional embedding을 더하여 spatial information을 유지한다. 이후 여러 카메라에서 추출된 image feature, 로봇의 joint position 또는 end-effector pose와 같은 proprioceptive state, 그리고 latent variable z 가 Transformer encoder로 입력된다. Transformer encoder는 다중 카메라 관측과 로봇 상태 정보를 통합하여 현재 작업 상태를 표현한다. 그 후 Transformer decoder는 고정된 action query를 사용하여 (k)개 시점의 action sequence를 생성한다. 이러한 구조는 시각 정보와 로봇 상태 정보를 동시에 고려하면서, 시간적으로 일관된 action chunk를 예측할 수 있도록 한다.

ACT는 action chunking만으로 끝나지 않고, temporal ensembling을 함께 사용한다. 단순한 action chunking에서는 정책이 k step마다 새로운 관측을 받아 k 개의 행동을 예측하고 순차적으로 실행한다. 그러나 이 방식은 새로운 관측이 반영되는 시점마다 action sequence가 급격히 바뀔 수 있어 불연속적이거나 jerky한 동작을 유발할 수 있다. 이를 완화하기 위해 ACT는 매 time step마다 policy를 query하여 overlapping


action chunks를 생성하고, 동일한 시점에 대해 여러 번 예측된 action들을 가중 평균한다. 예를 들어, 특정 시점 t 에 대해 여러 action chunk에서 예측된 후보 행동들이 존재할 때, 최종 행동은 다음과 같이 계산된다.

$$a_t = \frac{\sum_i w_i \hat{a}_t^i}{\sum_i w_i}, w_i = \exp(-mi) \quad (8)$$

여기서 $\hat{a}_t^i$ 는 동일 시점 t 에 대해 서로 다른 action chunk에서 예측된 행동을 의미하고, w_i 는 exponential weighting factor이다. Temporal ensembling은 서로 다른 시점에서 예측된 action 후보를 부드럽게 결합함으로써 action의 불연속성을 줄이고, 고주파 제어에서 더 안정적인 움직임을 생성하도록 한다. 일반적인 smoothing과 달리, temporal ensembling은 인접 time step의 action을 평균하는 것이 아니라 동일한 time step에 대해 예측된 action 후보들을 평균한다는 점에서 시간 지연이나 trajectory bias를 줄일 수 있다.

본 연구에서는 ACT를 제안하는 Res-IL 프레임워크의 nominal imitation policy로 사용한다. ACT는 다중 시점 관측으로부터 시간적으로 일관된 action chunk를 생성할 수 있기 때문에, 협동 양팔 조작에서 기본적인 작업 수행 motion prior를 학습하는 데 적합하다. 그러나 ACT는 본질적으로 시연된 동작 궤적을 재현하는 behavior cloning 기반 정책이므로, 두 로봇 팔이 동일한 물체를 동시에 조작할 때 발생하는 내부 힘이나

force inconsistency를 명시적으로 최소화하지는 않는다. 따라서 본 연구에서는 ACT가 예측한 nominal action을 기준으로 residual QP 기반 보정 행동을 계산하여, 작업 수행 동작은 유지하면서 폐쇄-체인 접촉으로 인해 발생하는 내부 힘을 줄이고자 한다.



[Fig 5] Architecture of Action Chunking with Transformer (ACT)

3.2. Control Barrier Function as a Safety Constraint

로봇 조작에서 학습 기반 정책은 복잡한 관측 정보로부터 행동을 직접 생성할 수 있다는 장점을 가지지만, 실행 과정에서 안전 제약을 항상 만족한다고 보장하기는 어렵다 [48], [55], [56]. 특히 접촉이 많은 조작 작업이나 협동 양팔 조작에서는 정책이 생성한 작은 행동 오차가 물체와의 접촉을 통해 큰 힘 또는 자세 변화로 이어질 수 있다 [37]-[45], [46], [47]. 따라서 학습 기반 정책을 실제 로봇 조작에 적용하기 위해서는 정책이 생성한 행동이 작업 수행 능력을 유지하는 동시에, 로봇의 기구학적·동역학적 안전 조건을 위반하지 않도록 제한할 필요가 있다.

Control Barrier Function(CBF)은 이러한 안전 제약을 수식적으로 표현하고, 제어

입력이 사전에 정의된 safe set 내부에 시스템 상태를 유지하도록 하는 방법이다 [52]-[54]. CBF의 핵심 목적은 시스템이 안전한 상태에서 시작했을 때, 적절한 제어 입력을 통해 이후 시간에도 계속 안전한 영역 안에 머물도록 하는 것이다 [52]-[54]. 이를 forward invariance라고 하며, 로봇 제어에서는 collision avoidance, joint limit avoidance, singularity avoidance, manipulability preservation 등 다양한 안전 조건을 만족시키는 데 활용될 수 있다 [52]-[56], [58].

일반적으로 CBF는 다음과 같은 control-affine system에 대해 정의된다.

$$\dot{x} = f(x) + g(x) \cdot u \quad (9)$$

여기서 x 는 안전성을 평가하기 위한 시스템 상태이며, 로봇의 관절 위치, 관절 속도, 말단 장치 자세 등을 포함할 수 있다. u 는 시스템에 적용되는 제어 입력이다. 안전 영역은 barrier function $h(x)$ 를 이용하여 다음과 같이 정의된다.

$$C = \{x \in R^n | h(x) \geq 0\} \quad (10)$$

즉, $h(x)$ 가 0 이상이면 시스템 상태 x 는 safe set C 내부에 존재한다고 볼 수 있다.

반대로 $h(x) < 0$ 인 경우에는 시스템이 안전하지 않은 영역에 있다고 해석할 수 있다.

CBF는 시스템 상태가 이 safe set을 벗어나지 않도록 다음 조건을 부과한다.

$$\dot{h}(x) \geq -\gamma \cdot h(x), \quad \gamma > 0 \quad (11)$$

여기서 γ 는 safe set 경계 근처에서 제약의 강도를 조절하는 양의 상수이다. 이 조건

은 $h(x)$ 가 0에 가까워질수록, 즉 시스템이 safe set의 경계에 접근할수록 $\dot{h}(x)$ 가 너무 작아지는 것을 방지하고, 결과적으로 시스템이 안전 영역 밖으로 빠져나가는 것을 억제한다.

CBF 조건은 chain rule을 이용하여 다음과 같이 전개할 수 있다.

$$\dot{h}(x) = \nabla h(x)^T \cdot \dot{x} \quad (12)$$

$$\dot{h}(x) = \nabla h(x)^T (f(x) + g(x) \cdot u) \quad (13)$$

따라서 CBF 조건은 제어 입력 u 에 대한 부등식 제약으로 표현될 수 있다.

$$\nabla h(x)^T g(x) \cdot u \geq -\nabla h(x)^T f(x) - \gamma h(x) \quad (14)$$

이 식은 최적화 기반 제어 문제에서 inequality constraint로 쉽게 포함될 수 있다. 예를 들어, nominal controller 또는 학습 기반 policy가 제어 입력을 예측하면, CBF 기반 safety filter는 해당 입력을 가능한 한 적게 수정하면서 위의 안전 조건을 만족하는 새로운 입력을 계산할 수 있다. 이러한 구조는 학습 기반 정책의 표현 능력과 최적화 기반 제어의 안전 보장 능력을 결합할 수 있다는 장점을 가진다.

본 연구의 협동 양팔 조작 문제에서는 내부 힘을 줄이기 위한 residual action이 항상 안전한 방향으로 작용한다고 보장할 수 없다. Residual QP는 손목 F/T feedback으로부터 정의된 internal-force proxy를 줄이는 방향으로 보정 행동을 계산하지만, 내부 힘만을 최소화하면 특정 상황에서 과도한 보정이 발생할 수 있다. 예를 들어, residual

action이 순간적으로 force mismatch를 줄이는 방향으로 계산되더라도, 그 결과 로봇 팔이 singularity에 가까운 자세로 이동하거나 manipulability가 낮아지는 경우에는 폐쇄체인 조작의 안정성이 오히려 저하될 수 있다. 따라서 residual QP에는 내부 힘 저감 목적과 함께 기구학적 안전성을 유지하기 위한 제약이 필요하다.

이를 위해 본 연구에서는 manipulability 기반 CBF를 safety constraint로 사용한다. Manipulability는 로봇이 현재 자세에서 말단 장치를 여러 방향으로 얼마나 자유롭게 움직일 수 있는지를 나타내는 지표이다. 로봇의 Jacobian을 $J(q)$ 라고 할 때, Yoshikawa manipulability measure [58]는 다음과 같이 정의된다.

$$\mu(q) = \sqrt{\det(J(q)J(q)^T)} \quad (15)$$

여기서 q 는 로봇의 관절 위치를 의미한다. Manipulability 값이 크다는 것은 로봇이 현재 자세에서 다양한 방향으로 말단 장치를 움직일 수 있음을 의미한다. 반대로 singularity 근처에서는 Jacobian의 rank가 감소하고 manipulability 값이 작아진다. 이 경우 작은 입력 변화에도 큰 관절 속도나 불안정한 말단 장치 움직임이 발생할 수 있으므로, 접촉 조작에서는 특히 주의가 필요하다.

Manipulability 기반 CBF에서는 barrier function을 다음과 같이 정의할 수 있다.

$$h(q) = \mu(q) - \mu_{\min} \quad (16)$$

여기서 $\mu_{\min}$ 은 허용 가능한 최소 manipulability 값이다. 따라서 $h(q) \geq 0$ 은 로봇의

manipulability가 최소 기준 이상으로 유지되고 있음을 의미한다. 이 조건을 CBF inequality로 변환하면, residual action은 내부 힘을 줄이는 방향으로 계산되더라도 manipulability를 지나치게 낮추는 방향으로 선택될 수 없다.

본 연구의 Res-IL 구조에서 실제 실행 입력은 nominal imitation policy가 예측한 행동 $\hat{a}$ 와 residual QP가 계산한 보정 행동 a_{res} 의 합으로 정의된다.


$$u_t = \hat{a}_t + a_{res,t} \quad (17)$$

따라서 CBF constraint는 residual action만을 별도로 제한하는 것이 아니라, 최종적으로 로봇에 적용되는 실행 입력 u 가 safe set을 유지하도록 제한한다. 즉, residual QP는 internal-force proxy를 최소화하는 동시에, CBF 제약을 만족하는 범위 안에서만 보정 행동을 선택한다. 이를 통해 Res-IL은 작업 수행 동작을 보존하면서도 내부 힘을 줄이고, 동시에 기구학적으로 불안정한 자세로 이동하는 것을 방지할 수 있다.

결과적으로 CBF는 본 연구에서 두 가지 역할을 수행한다. 첫째, residual QP가 내부 힘을 줄이는 과정에서 과도하거나 비현실적인 보정 행동을 생성하지 않도록 제한한다. 둘째, 협동 양팔 조작 중 로봇이 낮은 manipulability 또는 singularity 근처로 이동하는 것을 방지하여, 폐쇄-체인 접촉에서의 조작 안정성을 향상시킨다. 따라서 CBF는 단순한 추가 제약이 아니라, force-aware residual correction이 실제 로봇 조작에서 안전하고 안정적으로 동작하도록 만드는 핵심적인 safety filter로 볼 수 있다.

4. Proposed Work

4.1. Overview of the Proposed Framework



[Fig 6] Overview of the Res-IL Architecture

본 연구에서는 협동 양팔 조작에서 발생하는 내부 힘을 줄이기 위해 [Fig 6]과 같이 Residual QP-based Imitation Learning(Res-IL) 프레임워크를 제안한다. 협동 양팔 조작에서는 두 로봇 팔이 동일한 물체를 동시에 파지하고 조작하기 때문에, 물체를 매개로 두 팔 사이에 폐쇄-체인(closed-chain)이 형성된다. 이때 각 팔의 미세한 동작 불일치나 접촉 상태의 변화는 물체의 운동에는 직접적으로 기여하지 않으면서도, 조작 안정성을 저하시킬 수 있는 내부 힘(internal force)을 유발할 수 있다.

기존 모방학습 기반 정책은 주로 시연된 동작 궤적을 재현하도록 학습된다. 따라서 정책이 작업 수행에 필요한 동작을 생성하더라도, 실행 중 발생하는 물리적 상호작용 힘

을 명시적으로 줄이도록 설계되어 있지는 않다. 특히 두 팔이 동일 물체를 동시에 구속하는 상황에서는 단순한 motion imitation만으로는 두 팔 사이의 힘 불일치를 충분히 조절하기 어렵다.

제안하는 Res-IL의 핵심 아이디어는 기존 모방학습 정책이 생성한 작업 동작을 유지하면서, 접촉 이후 발생하는 내부 힘을 최적화 기반 보정으로 줄이는 것이다. 이를 위해 Res-IL은 nominal imitation policy가 예측한 행동을 완전히 대체하지 않고, 해당 행동 주변에서 최소한의 residual action을 계산한다. 최종 실행 행동은 다음과 같이 표현된다.


$$a_t^* = \hat{a}_t + a_{res,t}^* \quad (18)$$

여기서 $\hat{a}_t$ 는 nominal imitation policy가 예측한 행동이고, $a_{res,t}^*$ 는 residual QP를 통해 계산된 보정 행동이다. 즉, Res-IL은 학습 기반 정책의 task execution capability를 유지하면서, F/T feedback을 이용해 물리적으로 더 일관된 행동을 생성하는 구조이다.

전체 프레임워크는 [Fig 6]과 같이 세 단계로 구성된다. 첫 번째 단계에서는 ACT 기반 nominal imitation policy를 시연 데이터로 학습한다. 두 번째 단계에서는 행동 변화가 내부 힘 변화에 미치는 영향을 예측하는 delta wrench predictor를 학습한다. 세 번째 단계에서는 학습된 nominal policy와 delta wrench predictor를 residual QP에

결합하여, 내부 힘을 줄이기 위한 보정 행동을 계산하고 이를 policy fine-tuning 과정에 통합한다.

4.2. Stage 1: Pre-training of Nominal Imitation Policy



[Fig 7] Pre-training Nominal Imitation Policy

Res-IL의 첫 번째 단계에서는 작업 수행에 필요한 기본 동작을 학습하기 위해 [Fig 7]의 구조를 가지는 nominal imitation policy를 사전 학습한다. 본 연구에서는 Action Chunking Transformer(ACT)를 nominal policy backbone으로 사용한다. ACT는 현재 관측으로부터 단일 행동만을 예측하는 일반적인 behavior cloning 정책과 달리, 여러 시점의 미래 행동 sequence를 action chunk 형태로 예측한다. 이러한 action chunking 구조는 시간적으로 일관된 행동 생성을 가능하게 하며, 접촉 조작에서 발생할

수 있는 행동 불연속성을 줄이는 데 효과적이다.

모델 학습에 사용되는 시연 데이터셋은 다음과 같이 정의된다.

$$D^i = \{(o_1^i, a_1^i), (o_2^i, a_2^i), \dots, (o_T^i, a_T^i)\}, \quad i \in [1, N] \quad (19)$$

여기서 o_t^i 는 i 번째 시연의 시점 t 에서의 관측이고, a_t^i 는 해당 시점의 expert action이다.

본 연구에서 관측은 multi-view RGB image와 로봇의 end-effector pose를 포함한다.

ACT는 CVAE 기반 구조를 사용하여 demonstration action chunk와 관측으로부터

latent variable z 를 추정하고, 이를 바탕으로 미래 action sequence를 예측한다.

$$z \sim q_\phi(z | a_{t:t+k}, \bar{o}_t) \quad (20)$$

$$\hat{a}_{t:t+k} = \pi_\theta(\hat{a}_{t:t+k} | o_t, z) \quad (21)$$


여기서 k 는 action chunk horizon이며, o_t 는 encoder context feature를 의미한다. 학습 과정에서 CVAE encoder는 관측과 실제 action chunk를 바탕으로 latent variable을 추정하고, decoder는 현재 관측과 latent variable을 조건으로 미래 action sequence를 복원하고, 이를 통해 policy는 시연 데이터에 포함된 작업 수행 동작의 시간적 구조를 학습한다.

Stage 1의 목적은 협동 양팔 조작을 수행하기 위한 task-consistent motion prior를 학습하는 것이다. 그러나 이 단계에서 학습된 nominal policy는 시연된 동작을 재현하도록 학습될 뿐, 폐쇄-체인 접촉에서 발생하는 내부 힘을 명시적으로 줄이도록 학습되

지는 않는다. 따라서 Stage 1 policy는 작업 수행을 위한 기본 행동 생성기로 사용되며, 내부 힘 저감은 이후 Stage 2와 Stage 3에서 추가적으로 다룬다.

4.3. Stage 2: Pre-training the Delta Wrench Predictor

Stage 2: Pre-training delta wrench predictor



[Fig 8] Pre-training Delta Wrench Predictor

두 번째 단계에서는 행동 변화가 내부 힘 변화에 미치는 영향을 예측하기 위해 [Fig 8]과 같은 구조로 delta wrench predictor를 학습한다. 협동 양팔 조작에서 내부 힘은 물체의 형상, 접촉 위치, 마찰 조건, 파지 자세, 로봇의 순응성, 두 팔의 상대적 움직임 등에 의해 결정된다. 이러한 접촉 동역학은 매우 복잡하므로, 행동 변화가 내부 힘에 미치는 영향을 해석적 모델로 정확하게 표현하기 어렵다.

이를 해결하기 위해 본 연구에서는 학습 기반 예측 모델 f_ψ 를 사용한다. Delta wrench predictor는 최근 observation history $o_{t-l:t}$ 와 action perturbation Δa_t 를 입력으로 받아, 다음 시점의 internal-force proxy 변화량을 예측한다.

$$\Delta \hat{W}_{int,t+1}^w = f_\psi(o_{t-l:t}, \Delta a_t) \quad (22)$$

여기서 $o_{t-l:t}$ 는 최근 1개 시점의 관측 이력이며, end-effector pose, joint position, internal-force proxy를 포함한다. Δa_t 는 현재 행동 변화량이다.

본 연구에서 internal-force proxy는 양쪽 손목에서 측정된 wrench의 차이로 정의된다.

$$W_{int,t}^w := F_{r,t}^w - F_{l,t}^w \quad (23)$$

여기서 $F_{r,t}^w$ 와 $F_{l,t}^w$ 는 각각 world frame에서 표현된 오른쪽 및 왼쪽 손목 wrench이다. 이 값은 object-level internal force를 정확히 분해한 값은 아니지만, 협동 box-lifting task에서는 두 팔 사이의 load-sharing mismatch를 반영하는 실용적인 proxy로 사용될 수 있다.

현재 시점의 internal-force proxy가 이고, predictor가 예측한 변화량이 $\Delta W_{int,t+1}^w$ 일 때, 다음 시점의 internal-force proxy는 다음과 같이 예측된다.


$$\hat{W}_{int,t+1}^w = W_{int,t}^w + \Delta \hat{W}_{int,t+1}^w \quad (24)$$

또한 f_ψ 는 differentiable model이므로, 행동 변화에 대한 internal-force proxy 변화의 민감도를 Jacobian으로 계산할 수 있다.

$$J_w = \frac{\partial f_\psi(o_{t-l:t}, \Delta a_t)}{\partial \Delta a_t} \quad (25)$$

이 J_w 는 Stage 3에서 residual action이 internal-force proxy에 미치는 영향을 선형 근사하는 데 사용된다. 즉, delta wrench predictor는 residual QP가 명시적인 접촉 모델 없이도 corrective action이 내부 힘에 미치는 영향을 추정할 수 있도록 하는 local surrogate model의 역할을 수행한다.

4.4. Stage 3: Fine-tuning and Inference with Res-IL



[Fig 9] Fine-tuning and Inference with Res-IL

세 번째 단계에서는 pretrained nominal imitation policy와 delta wrench predictor를 결합하여 residual QP 기반 fine-tuning 및 inference를 수행한다. 먼저

nominal policy가 현재 관측 o_t 로부터 nominal action a_t 를 예측한다. 이후 Stage 2에서 사용한 정의와 동일하게 nominal delta action을 계산한다.

$$\Delta \hat{a}_t = \hat{a}_t - \hat{a}_{t-1} \quad (26)$$

Delta wrench predictor는 최근 observation history $o_{t-l:t}$ 와 $\Delta \hat{a}_t$ 를 입력으로 받아 다음 시점의 internal-force proxy 변화량과 wrench sensitivity matrix J_w 를 계산한다. 이때 residual action $a_{res,t}$ 가 추가되었을 때의 internal-force proxy는 다음과 같이 선형 근사된다.

$$W_{int}^w(\hat{a}_t, a_{res,t}) \approx \hat{W}_{int,t+1}^w + J_w a_{res,t} \quad (27)$$

이를 바탕으로 Res-IL은 다음 residual QP를 풀어 내부 힘을 줄이는 보정 행동을 계산한다.

$$a_{res,t}^* = \arg \min_{a_{res,t}} \alpha \left\| W_{int}^w(\hat{a}_t, a_{res,t}) \right\|_2^2 + \beta \left\| a_{res,t} \right\|_2^2 \quad (28)$$

여기서 첫 번째 항은 predicted next-step internal-force proxy를 줄이기 위한 항이고, 두 번째 항은 residual correction의 크기를 제한하기 위한 regularization 항이다. α 와 β 는 내부 힘 저감과 nominal action 보존 사이의 trade-off를 조절한다.

실제 구현에서는 residual action이 과도하게 커지는 것을 방지하기 위해 element-wise box constraint를 추가한다.

$$-\tau \leq a_{res,t} \leq \tau \quad (29)$$

또한 residual QP에는 manipulability-based Control Barrier Function(CBF) 제약을 포함한다. 이는 내부 힘을 줄이는 과정에서 보정 행동이 로봇을 낮은 manipulability 영역이나 singularity 근처로 유도하지 않도록 하는 safety constraint이다. 따라서 Res-IL의 residual QP는 내부 힘 저감, residual action regularization, bounded correction, 기구학적 안전성을 동시에 고려하는 constrained optimization problem으로 볼 수 있다.

Fine-tuning 과정에서는 residual QP를 통해 계산된 corrected action을 policy가 다시 회귀하도록 학습한다. 구체적으로 policy를 rollout하면서 각 시점에서 corrected action a_t^* 를 계산하고, nominal policy output a_t 가 이 corrected action에 가까워지도록 다음 손실을 최소화한다.

$$L_{stage3} = \left\| \hat{a}_t - a_t^* \right\|_2^2 \quad (30)$$

이 과정은 residual QP가 생성한 force-aware correction을 policy parameter에 반영하는 역할을 한다. 만약 residual QP를 inference 단계에만 적용하면, 학습 시 policy가 경험한 action distribution과 실제 실행 시 corrected action distribution 사이에 불일치가 발생할 수 있다. 협동 양팔 조작에서는 작은 행동 변화도 접촉 조건과 force distribution을 바꿀 수 있기에, 이러한 training-validation mismatch는 조작 안정성에 부정적인 영향을 줄 수 있다. 따라서 본 연구에서는 corrected action을


policy fine-tuning에 사용하여, policy 자체가 residual-force-aware behavior에 적응하도록 한다.

Inference 단계에서 Res-IL은 다음 순서로 동작한다. 먼저 현재 multi-view RGB image와 end-effector pose를 nominal ACT policy에 입력하여 a_t 를 예측한다. 이후 최근 observation history와 Δa_t 를 delta wrench predictor에 입력하여 $\Delta W_{int,t+1}^w$ 와 J_w 를 계산한다. 그 다음 residual QP를 풀어 $a_{res,t}^*$ 를 얻고, 최종적으로 다음과 같은 action을 실행한다.

$$a_t^* = \hat{a}_t + a_{res,t}^* \quad (31)$$

Residual QP는 free-space motion 동안 항상 활성화되지 않는다. 내부 힘 저감은 물리적 접촉이 형성된 이후에 의미가 있기 때문에, 본 연구에서는 접촉이 감지된 이후에 residual QP를 활성화한다.

결과적으로 Stage 3는 Res-IL의 핵심 단계로, nominal imitation policy의 작업 수행 능력을 유지하면서 residual QP를 통해 접촉 이후 발생하는 내부 힘을 줄인다. 또한 corrected action을 fine-tuning에 사용함으로써, policy가 학습 단계와 실행 단계에서 일관된 force-aware action distribution을 갖도록 한다.




[Fig 10] Overall Architecture of the Proposed Res-IL Framework

5. Experiments

5.1. Experimental Settings

5.1.1. Simulation Setting



[Fig 11] MuJoCo Environment for Simulation Experiment

본 연구에서는 제안한 Res-IL이 폐쇄-체인 조건에서 발생하는 내부 힘을 효과적으로 줄일 수 있는지 검증하기 위해 [Fig 11]과 같이 MuJoCo 기반 협동 양팔 조작 시뮬레이션 환경을 구성하였다. 실험 task는 두 로봇 팔이 동일한 강체 박스를 동시에 파지하고 들어 올리는 cooperative bimanual box-lifting task로 설정하였다. 이 작업에서는 두 끝단이 하나의 물체를 동시에 구속하므로, 로봇-물체-로봇으로 이어지는 폐쇄-체인(closed-chain)이 자연스럽게 형성된다. 이러한 조건에서는 양팔의 작은 동작 불일치나 접촉 위치 차이가 물체를 통해 상호작용 힘으로 전달될 수 있으며, 결과적으로 물체의 운동에는 기여하지 않는 내부 힘이 발생할 수 있다. 시뮬레이션에서 조작 대상은 강체 박스로 모델링하였으며, gripper와 물체 사이의 접촉은 MuJoCo soft contact model을 이용하여 구현하였다. 실험에 사용한 주요 물체 및 접촉 파라미터는 [Table 1]과 같다.

정책 학습에는 네 개의 RGB 카메라 영상, 로봇의 end-effector pose, 그리고 wrist-mounted F/T sensor 측정값을 포함한 multimodal observation을 사용하였다. F/T signal에 low-pass filtering을 적용할 경우 센서 노이즈를 완화할 수 있지만, 동시에 시간 지연이 발생하여 residual correction이 실제 물리적 접촉 변화보다 늦게 반응할 수 있다. 따라서 본 시뮬레이션 실험에서는 residual QP가 접촉 상황에 즉각적으로 반응할 수 있도록 raw F/T measurement를 사용하였다.

[Table 1] Simulation and Contact Parameters used in Experiments


Item	Value / Description
Object model	Rigid box
Object size	$0.33 \times 0.25 \times 0.16$ (m)
Object mass	0.2 (kg)
Contact model	MuJoCo soft contact
Contact dimension	condim=4
Contact reference	solref="0.01 1"
Contact impedance	solimp="2 1 0.01"
Friction parameters	friction="1 0.005 0.0001"
Control timestep	0.02 (s)
Control frequency	50 (Hz)
Closed-chain condition	Both grippers contact the box
QP activation	Box held by both grippers and not touching table

성능 비교를 위해 두 가지 모델을 사용하였다. 첫 번째는 Action Chunking Transformer(ACT) baseline으로, 시연 데이터로부터 reference action을 직접 예측하는 unconstrained imitation policy이다. 두 번째는 본 연구에서 제안하는 Res-IL로,

ACT baseline에 residual QP 기반 보정 모듈을 추가한 모델이다. 두 모델은 공정한 비교를 위해 동일한 ACT backbone과 학습 설정을 사용하였으며, baseline ACT는 ResNet visual encoder와 CVAE 기반 Transformer encoder-decoder 구조를 사용한다. 학습 데이터는 총 200개의 expert demonstration으로 구성하였으며, Res-IL의 residual QP 파라미터는 $\alpha=1.0$, $\beta=1.0$ 으로 설정하였다.

Residual QP는 전체 trajectory 동안 항상 활성화되지 않는다. 내부 힘 저감은 물체와 양팔 사이의 물리적 접촉이 형성된 이후에 의미가 있기 때문에, free-space motion 구간에서는 residual QP를 비활성화하였다. 시뮬레이터의 contact detector를 매 timestep 확인하여, 박스가 양쪽 gripper와 동시에 접촉하고 더 이상 table과 접촉하지 않는 경우에만 residual QP를 활성화하였다. 이는 두 팔이 물체를 함께 파지한 상태로 공중에서 유지하는 two-hand in-air hold 상태를 의미하며, 본 연구에서는 이 구간을 폐쇄-체인 manipulation phase로 간주하였다.

5.1.2. Real-world Hardware Setting



[Fig 12] Real-world Environment for Hardware Experiment

본 연구에서는 시뮬레이션 환경에서 검증한 Res-IL 프레임워크의 실제 적용 가능성을 확인하기 위해 Franka Research 3 기반 협동 양팔 로봇 실험 환경을 구성하였다. 실험 환경은 [Fig 12]와 같이 두 대의 Franka Research 3 로봇 팔이 하나의 강체 물체를 동시에 파지하고 조작할 수 있도록 배치하였다. 두 로봇 팔은 서로 마주 보는 형태를 설치되었으며, 중앙에는 box-lifting task를 위한 조작 대상 물체를 배치하였다. 이 구성에서는 두 로봇 팔이 동일한 물체를 동시에 구속하므로, 시뮬레이션 실험과 마찬가지로 로봇-물체-로봇으로 이어지는 폐쇄-체인 조건이 형성된다.

실제 하드웨어 실험에는 [Fig 13]과 같이 두 대의 Franka Research 3(FR3) 로봇 팔을 사용하였다. FR3는 7-자유도 구조를 갖는 협동 로봇 팔로, 각 관절에 torque sensor가 내장되어 있어 접촉 기반 조작 실험에 적합하다. 각 로봇 팔은 최대 3 kg의 payload와 855 mm의 reach를 가지며, 1 kHz 제어 주기를 지원한다. FR3의 상세 사양은 [Table 2]에 제시하였다. 본 연구에서는 양팔이 물체를 동시에 파지하고 들어 올리는 과정에서 발생하는 동작 및 힘 상호작용을 관찰하기 위해 해당 플랫폼을 사용하였다. 한편, 본 하드웨어 구성에서는 별도의 wrist-mounted F/T sensor를 사용하지 않았으므로, 손목에서의 실제 F/T 측정값 대신, 손목 관절의 torque sensor와 로봇의 기구학적 모델을 기반으로 추정된 F/T 정보를 사용하였다.



[Fig 13] Franka Research 3 used in this Research

[Table 2] Specification of Franka Research 3

Component	Specification
Robot model	Franka Research 3
Robot type	7-DoF collaborative robotic arm
Degrees of freedom (DoF)	7
Payload	3 (kg)
Reach	855 (mm)
Position repeatability	$< \pm 0.1$ (mm)
Torque sensing	7 integrated joint torque sensors
Control frequency	1 kHz

이미지 관측값 수집을 위해 총 3대의 Intel Realsense D435 RGB 카메라를 사용하였다. 카메라는 작업 공간을 서로 다른 시점에서 관측할 수 있도록 배치하였으며, 이를 통해 물체의 위치, 양팔의 접근 방향, 그리고 파지 상태를 관찰하였다. 본 연구에서는 Realsense D435의 depth stream은 사용하지 않고 오직 RGB stream만을 사용하였다. Intel Realsense D435의 상세 사양은 [Table 3]에 제시하였다. 각 카메라에서 취득한 RGB 영상은 policy의 visual observation으로 사용되며, 로봇의 proprioceptive state와 함께 입력으로 구성된다. 즉, 실제 하드웨어 환경에서의 policy input은 multi-view RGB images와 양팔 로봇의 end-effector pose로 구성된다.



[Fig 14] Intel Realsense D435

[Table 3] Specification of Intel Realsense D435

Component	Specification
Camera model	Intel Realsense Depth Camera D435
Depth resolution	1280 x 720 (used resolution: 640 x 480)
Depth field of view	85.2° × 58°
Operating range	Approx. 0.3-3.0 m
RGB sensor	Supported
Dimensions	90 × 25 × 25 mm

실험 task는 시뮬레이션과 동일하게 두 로봇 팔이 하나의 물체를 동시에 파지하고 들어 올리는 cooperative bimanual box-lifting task로 설정하였다. 이 작업에서는 두 end-effector가 물체를 동시에 구속하기 때문에, 양팔 사이의 미세한 위치 또는 자세 불일치가 물체를 통해 상호작용 힘으로 전달될 수 있다. 따라서 실제 하드웨어 실험은 Res-IL이 시뮬레이션뿐만 아니라 실제 로봇 환경에서도 폐쇄체인 조작 중 발생하는 내부 힘을 줄이는 데 활용될 수 있는지를 확인하기 위한 목적으로 수행되었다.

실제 환경에서는 시뮬레이션과 달리 다양한 불확실성이 존재한다. 예를 들어 카메라 영상에는 조명 변화와 가림 현상이 포함될 수 있으며, 로봇 제어 과정에서는 통신 지연과 제어 오차가 발생할 수 있다. 또한 물체와 gripper 사이의 마찰 조건, 물체의 미세한

변형, 접촉 위치 변화 등은 시뮬레이션에서 완전히 재현하기 어렵다. 이러한 요인들은 협동 양팔 조작에서 내부 힘의 크기와 방향에 영향을 줄 수 있으므로, 실제 하드웨어 실험은 제안 방법의 실용성을 평가하는 데 중요한 의미를 가진다.

5.2. Simulation-based Evaluation

본 절에서는 MuJoCo 시뮬레이션 환경에서 ACT baseline과 제안하는 Res-IL의 성능을 비교한다. 평가 task는 두 로봇 팔이 동일한 rigid box를 동시에 파지하고 공중으로 들어 올리는 cooperative bimanual box-lifting task이다. Inference trial은 양쪽 end-effector가 박스를 안정적으로 파지하고 공중으로 들어 올리는 경우 성공으로 정의하였다. 내부 힘 저감 성능을 체계적으로 평가하기 위해, 시연 데이터 수집 시 neutral grasping pose를 기준으로 wrist pitch perturbation을 $[-30^\circ, +30^\circ]$ 범위에서 무작위로 부여하였다. 이러한 wrist perturbation은 양팔 사이의 상대적인 자세 불일치를 증가시켜, 폐쇄-체인 접촉 이후 내부 힘이 발생하기 쉬운 조건을 형성한다. 모든 정량 결과는 각 실험 조건에 대해 50회의 rollout 평균으로 계산하였다.

평가 지표는 task success rate, contact 이후의 peak force norm, mean force norm, peak torque norm, mean torque norm으로 구성하였다. Force norm과 torque norm은 wrist F/T feedback으로부터 정의된 internal-force proxy의 force component와 torque component를 각각 평가하기 위해 사용하였다. 이를 통해 단순


히 task를 성공했는지뿐만 아니라, 동일한 성공 조건을 만족하는 동안 양팔 사이에 발생하는 물리적 힘 불일치가 얼마나 줄어드는지를 함께 평가하였다.

[Table 4]와 [Table 5]는 ACT baseline, CBF를 제거한 Res-IL, 그리고 제안한 Res-IL의 정량 결과를 나타낸다. 먼저 ACT baseline과 제안 방법을 비교하면, 두 방법 모두 50/50의 동일한 task success rate를 달성하였다. 이는 residual QP correction이 nominal ACT action distribution에서 크게 벗어나지 않으며, task execution capability를 유지한다는 것을 보여준다. 그러나 동일한 성공 조건을 만족하더라도, ACT baseline은 공중에서 물체를 유지하는 동안 상대적으로 큰 내부 힘을 발생시키며 불안정한 holding behavior를 보인다. 반면 Res-IL은 residual QP를 통해 내부 힘을 줄이는 방향의 작은 corrective action을 생성함으로써, 물체를 더 안정적으로 유지하였다.

정량적으로 Res-IL은 ACT baseline 대비 peak force norm과 peak torque norm을 절반 이상 감소시켰다. 또한 contact 이후 평균 force norm은 10.21 N에서 6.227 N으로 감소하였으며, 평균 torque norm은 67.94 N·m에서 50.87 N·m으로 감소하였다. 이는 각각 39.0%와 25.1%의 감소율에 해당한다. 이러한 결과는 제안한 residual QP가 task-relevant motion을 유지하면서도 폐쇄체인 접촉에서 발생하는 내부 힘을 효과적으로 줄일 수 있음을 보여준다.

시간에 따른 force/torque norm 변화를 살펴보면, contact 이전의 free-space


motion 구간에서는 ACT baseline과 Res-IL이 유사한 wrench profile을 보인다. 이는 해당 구간에서 residual QP가 활성화되지 않기 때문이다. 반면 박스가 양쪽 gripper와 동시에 접촉하고 table에서 떨어진 closed-chain phase에 진입하면, Res-IL은 ACT baseline보다 낮은 force norm과 torque norm을 지속적으로 나타낸다. 즉, Res-IL의 성능 향상은 free-space motion에서의 단순한 trajectory 차이 때문이 아니라, 접촉 이후 residual QP가 내부 힘을 줄이는 방향으로 action을 보정한 결과로 해석할 수 있다.



[Fig 15] Qualitative Comparison of ACT baseline (Top) and Fine-tuned Res-IL (Bottom) in Simulation

[Table 4] Comparison between ACT baseline and Proposed Res-IL (Simulation)

Model	Success Rate	Force Norm (N)		Torque Norm (N·m)	
		Max	Mean	Max	Mean
ACT(baseline)	50/50	26.93	10.21	157.4	67.94
Res-IL(proposed)	50/50	8.313	6.227	70.78	50.87




[Fig 16] Internal-Force Proxy Comparison between ACT only and Fine-tuned Res-IL in Simulation

추가적으로, CBF constraint의 효과를 확인하기 위해 Res-IL with CBF와 Res-IL without CBF를 비교하였다. 두 모델 모두 50/50의 동일한 success rate를 달성하였지만, CBF constraint를 포함한 경우 peak wrench norm이 뚜렷하게 감소하였다. 구체적으로 CBF를 적용한 Res-IL은 CBF를 제거한 모델에 비해 peak force norm을 47.0%, peak torque norm을 33.5% 감소시켰다. 또한 contact 이후 mean force norm과 mean torque norm 역시 각각 40.7%, 26.9% 감소하였다.

이 결과는 CBF constraint가 단순한 safety filter를 넘어, residual QP 기반 내부 힘 저감 과정의 안정성과 일관성을 향상시키는 역할을 함을 의미한다. CBF가 없는 경우 residual QP는 internal-force proxy를 줄이기 위해 기구학적으로 불리하거나 불안정한 holding configuration을 유도할 수 있다. 반면 CBF를 포함하면 manipulability가 낮은 자세나 infeasible configuration으로 이동하는 것을 제한하면서 내부 힘을 줄일 수 있다. 따라서 CBF-constrained Res-IL은 폐쇄체인 접촉 조작에서 더 낮고 안정적인 wrench profile을 생성하며, force regulation의 분산도 줄이는 효과를 보인다.

종합하면, 시뮬레이션 기반 평가 결과는 제안한 Res-IL이 ACT baseline과 동일한 수준의 task success rate를 유지하면서도, contact 이후 발생하는 내부 힘을 유의미하게 줄일 수 있음을 보여준다. 특히 residual QP는 nominal ACT action 주변에서 작은 보정량만을 계산하기 때문에 작업 동작을 보존할 수 있으며, CBF constraint는 이러한


보정 과정이 기구학적으로 안정적인 범위 안에서 이루어지도록 한다. 이러한 결과는 협동 양팔 조작에서 단순한 motion imitation만으로는 물리적으로 일관된 조작을 보장하기 어렵고, force/torque feedback을 활용한 residual optimization이 안정적인 closed-chain manipulation에 효과적임을 보여준다.



[Fig 17] Qualitative Comparison of Res-IL without CBF (Top) and Res-IL with CBF (Bottom) in Simulation

[Table 5] Comparison between Res-IL w/o and w/ CBF (Simulation)

Model	Success Rate	Force Norm (N)		Torque Norm (N·m)	
		Max	Mean	Max	Mean
Res-IL(w/o CBF)	50/50	15.70	10.50	106.5	69.56
Res-IL(w/ CBF)	50/50	8.313	6.227	70.78	50.87



[Fig 18] Internal-Force Proxy Comparison between Res-IL without CBF and Res-IL with CBF in Simulation

5.3. Real-World Hardware-based Evaluation

본 절에서는 실제 하드웨어 환경에서 제안한 Res-IL의 적용 가능성을 정성적으로 평가한다. 시뮬레이션 실험에서는 MuJoCo에서 제공되는 안정적인 접촉 정보와 F/T 값을 기반으로 내부 힘 저감 효과를 검증하였다. 그러나 실제 로봇 환경에서는 센서 노이즈, 제어 지연, 카메라 관측 오차, 마찰 조건의 불확실성, 그리퍼와 물체 사이의 접촉 상태 변화 등이 존재한다. 따라서 실제 하드웨어 실험은 Res-IL이 시뮬레이션 조건을 넘어 실제 협동 양팔 조작 환경에서도 안정적으로 동작할 수 있는지를 확인하기 위해 수행하였다.

실험은 두 대의 Franka Research 3 로봇 팔을 이용한 cooperative bimanual box-lifting task로 구성하였다. 두 로봇 팔은 하나의 강체 물체를 동시에 파지한 뒤 공중으로 들어 올리며, 이 과정에서 로봇-물체-로봇으로 이어지는 폐쇄-체인 조건이 형성된다. 평가의 목적은 기존 ACT baseline과 제안한 Res-IL이 동일한 작업 성공 조건을 만족하는 동안, 양팔 사이의 힘 불일치를 얼마나 줄일 수 있는지를 비교하는 것이다.

본 하드웨어 구성에서는 별도의 wrist-mounted F/T sensor를 사용하지 않았기 때문에, 실제 손목 F/T 측정값 대신 Franka Research 3의 관절 torque sensor와 로봇의 기구학적 모델을 기반으로 추정된 힘/토크 정보를 활용하였다. 이를 통해 양팔의 wrist wrench 차이로 정의되는 internal-force proxy를 계산하고, ACT baseline과 Res-IL의 force norm 및 torque norm을 비교하였다. 시각 관측은 3대의 Intel

Realsense D435 RGB 카메라로부터 취득한 multi-view RGB images를 사용하였으며, 로봇의 end-effector pose와 함께 policy 입력으로 사용하였다.


평가 지표는 시뮬레이션 실험과 동일하게 task success rate, force norm, torque norm으로 구성하였다. Task success는 두 로봇 팔이 물체를 동시에 파지한 상태로 공중으로 들어 올리는 경우로 정의하였다. Force norm과 torque norm은 양팔 간 internal-force proxy의 force component와 torque component의 크기를 각각 나타내며, 접촉 이후 closed-chain manipulation 구간에서 계산하였다.

실험 결과, Res-IL은 ACT baseline과 유사한 수준의 작업 성공률을 유지하면서도 closed-chain manipulation 구간에서 각각 더 낮은 force/torque norm을 보였다. 이는 residual QP가 nominal policy의 작업 수행 동작을 크게 훼손하지 않으면서, 양팔 사이의 힘 불일치를 줄이는 방향으로 보정 행동을 생성했기 때문으로 해석할 수 있다. 특히 ACT baseline은 물체를 들어 올린 이후 양팔의 상대적인 자세 오차나 접촉 조건 변화로 인해 force/torque norm이 증가하는 경향을 보였다. 반면 Res-IL은 접촉 이후의 내부 힘 변화를 반영하여 residual action을 계산함으로써, 보다 안정적인 물체 유지 동작을 생성하였다.

정성적으로도 ACT baseline은 물체를 들어 올리는 과정에서 한쪽 팔이 더 큰 하중을 부담하거나, 물체가 미세하게 기울어지는 현상이 관찰되었다. 이러한 현상은 양팔의 동작이 시각적으로는 성공적으로 보이더라도, 실제 물리적 상호작용에서는 힘 분포가 일

관되지 않을 수 있음을 보여준다. 반면 Res-IL은 양팔 간 힘 불균형을 줄이는 방향으로 행동을 보정하여, 물체를 보다 안정적으로 유지하였다.

실제 하드웨어 실험 결과는 Res-IL이 시뮬레이션뿐만 아니라 실제 협동 양팔 조작 환경에서도 내부 힘 저감에 활용될 수 있음을 보여준다. ACT baseline은 시연 궤적을 재현하여 작업 성공 조건을 만족할 수 있지만, 폐쇄-체인 접촉 이후 발생하는 힘 불일치를 직접적으로 조절하지 못한다. 반면 Res-IL은 internal-force proxy를 최적화 신호로 활용하여, nominal action 주변에서 최소한의 보정 행동을 생성함으로써 보다 물리적으로 일관된 조작을 수행한다.



[Fig 19] Qualitative Comparison of ACT baseline (Left) and Fine-tuned Res-IL (Right) in Real-world Experiment

다만 실제 하드웨어 환경에서는 시뮬레이션과 달리 여러 불확실성이 존재한다. 본 연구에서는 별도의 wrist-mounted F/T sensor가 아닌 Franka Research 3의 관절 torque sensor와 로봇 모델 기반 추정치를 사용하였기 때문에, 추정된 손목 wrench에는 모델 오차와 센서 노이즈가 포함될 수 있다. 또한 카메라 관측 오차, 제어 지연, 마찰 조건 변화, 물체와 그리퍼 사이의 접촉 위치 변화도 residual QP의 보정 성능에 영

향을 줄 수 있다. 따라서 향후 연구에서는 보다 정밀한 wrist F/T sensing, filtering 및 temporal alignment, residual-action rate limiting 등을 적용하여 실제 환경에서의 강인성을 더욱 향상시킬 필요가 있다.

종합하면, 실제 하드웨어 기반 평가는 제안한 Res-IL이 task execution capability를 유지하면서도 내부 힘을 줄이는 방향으로 확장 가능성을 보여준다. 특히 residual QP는 기존 모방학습 정책이 생성한 작업 동작을 유지하면서, 접촉 이후 발생하는 물리적 힘 불일치를 줄이는 보정 구조로 활용될 수 있다. 이러한 결과는 Res-IL이 실제 접촉 기반 양팔 조작에서 안정적이고 물리적으로 일관된 행동 생성을 가능하게 하며, 향후 다양한 물체, 파지 조건, force/torque profile-following 작업으로 확장될 수 있음을 시사한다.

6. Conclusion and Future Work

6.1. Conclusion

본 연구에서는 협동 양팔 조작에서 발생하는 내부 힘 문제를 해결하기 위해 Residual QP-based Imitation Learning(Res-IL) 프레임워크를 제안하였다. 기존 모방 학습 기반 로봇 조작 정책은 주로 시연된 동작 궤적을 재현하는 데 초점을 맞추기 때문에, 두 로봇 팔이 동일한 물체를 동시에 조작하는 폐쇄체인 상황에서 발생하는 물리적 상호작용 힘을 명시적으로 고려하지 못한다. 특히 협동 양팔 조작에서는 두 팔이 물체를 통해 기구학적·동역학적으로 연결되므로, 각 팔의 작은 움직임 불일치도 물체의 운동에는 기여하지 않는 내부 힘으로 이어질 수 있다. 이러한 내부 힘은 조작 안정성을 저하시킬 뿐만 아니라, 구동기 부하를 증가시키고 장기적으로는 하드웨어 신뢰성에도 영향을 줄 수 있다.

이를 해결하기 위해 본 연구에서는 ACT 기반 nominal imitation policy에 residual Quadratic Programming(QP) 모듈을 결합하였다. 제안한 Res-IL은 nominal policy가 예측한 작업 동작을 직접 대체하지 않고, 해당 행동 주변에서 최소한의 residual action을 계산한다. 이 residual action은 손목 force/torque feedback으로부터 정의한 internal-force proxy를 줄이도록 설계되며, 동시에 nominal action과의 차이를 제한함으로써 작업 수행에 필요한 동작을 보존한다. 따라서 Res-IL은 모방학습 정책의 장점

인 시연 기반 행동 생성 능력을 유지하면서, 접촉 이후 발생하는 물리적 힘 불일치를 최적화 기반으로 보정할 수 있다.

또한 본 연구에서는 행동 변화가 내부 힘에 미치는 영향을 예측하기 위해 `delta wrench predictor`를 학습하였다. 실제 접촉 동역학은 물체 형상, 접촉 위치, 마찰 조건, 로봇 자세, 양팔의 상대적 움직임 등에 따라 복잡하게 변하기 때문에 해석적으로 모델링하기 어렵다. 본 연구에서는 최근 관측 이력과 행동 변화량을 입력으로 받아 다음 시점의 `internal-force proxy` 변화를 예측하는 학습 기반 모델을 사용하였다. 이를 통해 `residual QP`는 명시적인 접촉 모델 없이도 보정 행동이 내부 힘에 미치는 영향을 근사적으로 평가할 수 있다.

나아가 `residual QP` 보정을 단순히 추론 단계에만 적용하지 않고, 정책 `fine-tuning` 과정에도 통합하였다. 만약 `QP` 보정이 추론 시점에만 적용된다면, 학습 중 정책이 경험한 행동 분포와 실제 실행 시 사용되는 보정 행동 분포 사이에 불일치가 발생할 수 있다. 이러한 불일치는 접촉 조건이 민감하게 변하는 협동 양팔 조작에서 조작 안정성을 저하시킬 수 있다. 본 연구에서는 `QP-corrected action`을 정책이 다시 회귀하도록 학습함으로써, 정책 자체가 `force-aware action distribution`에 적응하도록 하였다. 이를 통해 학습과 실행 사이의 불일치를 줄이고, 보다 안정적인 접촉 조작을 가능하게 하였다.

실험에서는 MuJoCo 기반 협동 양팔 `box-lifting task`를 통해 제안 방법의 효과를 검

증하였다. 두 로봇 팔이 동일한 강체 물체를 동시에 파지하고 들어 올리는 상황에서, ACT baseline과 Res-IL의 작업 성공률 및 손목 force/torque norm을 비교하였다. 실험 결과, Res-IL은 baseline과 동일한 수준의 작업 성공률을 유지하면서도 평균 force norm과 torque norm을 각각 39.0%, 25.1% 감소시켰다. 이는 제안한 residual QP 보정이 task-relevant motion을 유지하면서도 폐쇄체인 접촉에서 발생하는 내부 힘을 효과적으로 줄일 수 있음을 보여준다.

또한 CBF(Control Barrier Function) 제약의 효과를 확인하기 위해 Res-IL with CBF와 Res-IL without CBF를 비교하였다. CBF 제약을 포함한 경우, peak force norm과 peak torque norm이 감소하였으며, 접촉 이후 wrench profile의 분산도 줄어드는 경향을 보였다. 이는 내부 힘을 줄이는 과정에서 단순한 wrench minimization 만으로는 충분하지 않으며, 보정 행동이 로봇을 기구학적으로 불안정한 자세로 유도하지 않도록 safety constraint를 함께 고려하는 것이 중요함을 의미한다.

결론적으로 본 연구는 협동 양팔 모방학습에서 내부 힘을 명시적으로 고려해야 함을 보였으며, 이를 위해 residual QP, delta wrench prediction, CBF constraint, 그리고 force-consistent fine-tuning을 결합한 Res-IL 구조를 제안하였다. 제안 방법은 단순한 동작 모방을 넘어, 물리적 힘 상호작용을 고려한 안정적인 협동 양팔 조작을 가능하게 하는 방향을 제시한다.

6.2. Limitation and Future Work

본 연구는 협동 양팔 조작에서 내부 힘 저감을 위한 Res-IL 프레임워크의 가능성을 보였지만, 다음과 같은 한계와 향후 연구 과제가 존재한다.

첫째, 본 연구는 MuJoCo 기반 시뮬레이션과 실제 하드웨어 실험을 통해 제안 방법의 유효성을 검증하였다. 시뮬레이션에서는 접촉 동역학과 F/T 정보를 비교적 안정적으로 관측할 수 있으며, 이를 바탕으로 Res-IL의 내부 힘 저감 효과를 정량적으로 평가할 수 있었다. 또한 실제 하드웨어 실험을 통해 제안 방법이 실제 로봇 시스템에서도 적용 가능함을 확인하였다. 그러나 실제 환경에서는 센서 노이즈, 제어 및 통신 지연, 마찰 계수의 불확실성, 물체의 미세한 변형, 그리고 그리퍼와 물체 사이의 접촉 상태 변화 등이 추가적으로 발생한다. 이러한 요인들은 residual QP가 사용하는 F/T feedback의 신뢰도에 영향을 줄 수 있으며, 특히 raw F/T signal을 직접 사용할 경우 고주파 성분의 노이즈가 residual action에 반영되어 불안정한 보정 행동을 유발할 수 있다. 따라서 향후 연구에서는 실제 하드웨어 검증을 다양한 작업 조건으로 확장하고, lightweight filtering, temporal alignment, residual-action rate limiting 등을 결합하여 센서 노이즈와 시간 지연에 강인한 force-aware residual correction 구조를 개발할 필요가 있다.

둘째, F/T signal filtering과 residual action의 반응성 사이의 trade-off를 고려해

야 한다. Low-pass filtering은 센서 노이즈를 줄이는 데 효과적이지만, 동시에 시간 지연을 발생시켜 실제 접촉 상태와 보정 action 사이의 temporal misalignment를 유발할 수 있다. 협동 양팔 조작에서는 접촉 상태가 빠르게 변할 수 있으므로, 지연된 force feedback은 오히려 부정확한 보정을 초래할 수 있다. 향후 연구에서는 lightweight filtering, cross-modal temporal alignment, residual-action rate limiting 등을 결합하여 신호 품질과 제어 반응성을 동시에 확보하는 방법을 연구할 필요가 있다.

셋째, 본 연구에서 사용한 internal-force proxy는 양쪽 wrist wrench의 차이를 기반으로 정의되었다. 이 proxy는 협동 box-lifting task에서 양팔 사이의 load-sharing mismatch를 반영하는 실용적인 지표로 사용할 수 있지만, object-level internal force를 완전하게 분해한 것은 아니다. 또한 squeeze grasp, 비대칭 파지, 다양한 마찰 조건, 물체 질량 변화가 존재하는 경우에는 단순한 bilateral wrench mismatch만으로 grasp stability와 internal force를 모두 설명하기 어려울 수 있다. 향후 연구에서는 물체 질량, 마찰 계수, 접촉 위치, 최소 파지력 조건 등을 함께 고려하여 internal-force proxy를 보다 일반화할 필요가 있다.

넷째, delta wrench predictor의 일반화 성능을 더욱 향상시킬 필요가 있다. 본 연구에서는 demonstration data를 기반으로 행동 변화와 internal-force proxy 변화 사이의 관계를 학습하였다. 그러나 실제 접촉 동역학은 작업 조건과 물체 특성에 따라 크게 달라질 수 있으며, demonstration data에 포함되지 않은 접촉 상황에서는

predictor의 예측 정확도가 저하될 수 있다. 향후 연구에서는 reinforcement learning 기반 탐색을 통해 다양한 접촉 조건에서 wrench variation을 학습하거나, uncertainty-aware prediction을 도입하여 predictor의 신뢰도를 residual QP에 반영하는 방법을 고려할 수 있다.

다섯째, 현재 Res-IL은 특정 협동 양팔 조작 task를 중심으로 설계 및 검증되었다. 그러나 실제 로봇 응용에서는 물체를 들어 올리는 작업뿐만 아니라 운반, 삽입, 조립, 회전, 밀기, 지지 등 다양한 형태의 협동 조작이 요구된다. 이러한 작업들은 서로 다른 접촉 조건과 힘 분포를 가지므로, residual QP의 목적 함수와 제약 조건을 task-specific하게 확장할 필요가 있다. 특히 작업에 따라 필요한 holding force와 줄여야 할 internal force가 다를 수 있으므로, 향후 연구에서는 task context를 반영한 adaptive residual QP formulation을 개발하는 것이 중요하다.

마지막으로, Res-IL을 Vision-Language-Action(VLA) 모델과 결합하는 방향도 고려할 수 있다. VLA 모델은 언어 명령과 시각 정보를 바탕으로 다양한 작업 목표를 이해하고 일반화하는 데 강점을 가지지만, 실제 접촉 조작에서는 의미적 이해뿐만 아니라 물리적으로 안정적인 힘 상호작용이 함께 요구된다. 향후 연구에서는 VLA 모델이 제공하는 task-level semantic information을 residual policy 또는 QP objective에 조건으로 반영하여, 작업 맥락에 따라 내부 힘을 줄이거나 목표 힘/토크 프로파일을 추종하는 방향으로 Res-IL을 확장할 수 있다. 예를 들어, 양팔로 핸들이나 밸브를 회전시키는 작업

에서는 단순한 힘 최소화가 아니라, 필요한 접촉 힘을 유지하면서 목표 힘 프로파일을 따라가도록 보정 행동을 생성할 수 있다. 이를 통해 다양한 작업 목표에 대해 맥락을 인지하고 물리적으로 일관된 협동 양팔 조작이 가능할 것으로 기대된다.

종합하면, 향후 연구는 실제 로봇 환경에서의 검증, 센서 노이즈와 시간 지연에 대한 강인성 확보, 다양한 물체 및 접촉 조건으로의 일반화, 그리고 task-level semantic understanding과 force-level physical consistency의 통합을 중심으로 진행될 필요가 있다. 이를 통해 Res-IL은 단일 시뮬레이션 작업을 넘어 실제 로봇 시스템에서 안정적이고 일반화 가능한 협동 양팔 조작 프레임워크로 발전할 수 있을 것으로 기대된다.

참고문헌

- [1] T. Z. Zhao, et al., "Learning fine-grained bimanual manipulation with low-cost hardware," arXiv preprint arXiv:2304.13705, 2023.
- [2] Z. Fu, T. Z. Zhao, and C. Finn, "Mobile ALOHA: Learning bimanual mobile manipulation with low-cost whole-body teleoperation," arXiv preprint arXiv:2401.02117, 2024.
- [3] T. Z. Zhao, et al., "ALOHA Unleashed: A simple recipe for robot dexterity," arXiv preprint arXiv:2410.13126, 2024.
- [4] F. Xie, et al., "Deep imitation learning for bimanual robotic manipulation," Advances in Neural Information Processing Systems, vol. 33, pp. 2327–2337, 2020.
- [5] S. Stepputtis, et al., "A system for imitation learning of contact-rich bimanual manipulation policies," in 2022 IEEE/RSJ International Conference on Intelligent Robots and Systems, IEEE, 2022.
- [6] F. Krebs and T. Asfour, "A bimanual manipulation taxonomy," IEEE Robotics and Automation Letters, vol. 7, no. 4, pp. 11031–11038, 2022.
- [7] B. D. Argall, S. Chernova, M. Veloso, and B. Browning, "A survey of robot learning from demonstration," Robotics and Autonomous Systems, vol. 57, no. 5, pp. 469–483, 2009.
- [8] H. Ravichandar, et al., "Recent advances in robot learning from demonstration," Annual Review of Control, Robotics, and Autonomous Systems, vol. 3, no. 1, pp. 297–330, 2020.

- [9] K. Sohn, H. Lee, and X. Yan, "Learning structured output representation using deep conditional generative models," *Advances in Neural Information Processing Systems*, vol. 28, 2015.
- [10] P. Florence, et al., "Implicit behavioral cloning," in *Conference on Robot Learning*, PMLR, 2022.
- [11] N. M. Shafiullah, et al., "Behavior transformers: Cloning k modes with one stone," *Advances in Neural Information Processing Systems*, vol. 35, pp. 22955–22968, 2022.
- [12] C. Chi, et al., "Diffusion policy: Visuomotor policy learning via action diffusion," *The International Journal of Robotics Research*, vol. 44, no. 10–11, pp. 1684–1704, 2025.
- [13] V. Saxena, Y. Koga, and D. Xu, "Constrained-context conditional diffusion models for imitation learning," *arXiv preprint arXiv:2311.01419*, 2023.
- [14] T. Buamanee, et al., "Bi-ACT: Bilateral control-based imitation learning via action chunking with transformer," in *2024 IEEE International Conference on Advanced Intelligent Mechatronics*, IEEE, 2024.
- [15] M. Kobayashi, T. Buamanee, and T. Kobayashi, "Alpha- α and Bi-ACT are all you need: Importance of position and force information/control for imitation learning of unimanual and bimanual robotic manipulation with low-cost system," *IEEE Access*, 2025.
- [16] T. Adachi, et al., "Imitation learning for object manipulation based on position/force information using bilateral control," in *2018 IEEE/RSJ International Conference on Intelligent Robots and Systems*, IEEE, 2018.

- [17] A. Sasagawa, et al., "Imitation learning based on bilateral control for human–robot cooperation," *IEEE Robotics and Automation Letters*, vol. 5, no. 4, pp. 6169–6176, 2020.
- [18] M. Kobayashi, et al., "ILBIT: Imitation learning for robot using position and torque information based on bilateral control with transformer," *IEEJ Journal of Industry Applications*, vol. 14, no. 2, pp. 161–168, 2025.
- [19] H. Sato, T. Tsuji, and S. Sakaino, "Force Generative Imitation Learning: Bridging Position Trajectory and Force Commands through Control Technique," *IEEE Access*, 2026.
- [20] A. Vaswani, et al., "Attention is all you need," *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [21] J. Devlin, et al., "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 2019.
- [22] N. Carion, et al., "End-to-end object detection with transformers," in *European Conference on Computer Vision*, Springer, 2020.
- [23] M. Shridhar, L. Manuelli, and D. Fox, "Perceiver-Actor: A multi-task transformer for robotic manipulation," in *Conference on Robot Learning*, PMLR, 2023.
- [24] A. Brohan, et al., "RT-1: Robotics transformer for real-world control at scale," *arXiv preprint arXiv:2212.06817*, 2022.

- [25] B. Zitkovich, et al., "RT-2: Vision-language-action models transfer web knowledge to robotic control," in Conference on Robot Learning, PMLR, 2023.
- [26] Octo Model Team, et al., "Octo: An open-source generalist robot policy," arXiv preprint arXiv:2405.12213, 2024.
- [27] M. J. Kim, et al., "OpenVLA: An open-source vision-language-action model," arXiv preprint arXiv:2406.09246, 2024.
- [28] K. Black, et al., "~~W~~ π_0 : A Vision-Language-Action Flow Model for General Robot Control," arXiv preprint arXiv:2410.24164, 2024.
- [29] Physical Intelligence, et al., " π 0.5: A Vision-Language-Action Model with Open-World Generalization," arXiv preprint arXiv:2504.16054, 2025.
- [30] D. Qu, et al., "SpatialVLA: Exploring spatial representations for visual-language-action model," arXiv preprint arXiv:2501.15830, 2025.
- [31] NVIDIA, J. Bjorck, et al., "GR00T N1: An open foundation model for generalist humanoid robots," arXiv preprint arXiv:2503.14734, 2025.
- [32] M. J. Kim, C. Finn, and P. Liang, "Fine-tuning vision-language-action models: Optimizing speed and success," arXiv preprint arXiv:2502.19645, 2025.
- [33] Z. Wang, et al., "MimicPlay: Long-horizon imitation learning by watching human play," arXiv preprint arXiv:2302.12422, 2023.
- [34] S. Kareer, et al., "EgoMimic: Scaling imitation learning via egocentric video," in 2025 IEEE International Conference on Robotics and Automation, IEEE,

2025.

- [35] N. R. Arachchige, et al., "SAIL: Faster-than-demonstration execution of imitation learning policies," arXiv preprint arXiv:2506.11948, 2025.
- [36] H. Bi, et al., "H-RDT: Human manipulation enhanced bimanual robotic manipulation," in Proceedings of the AAAI Conference on Artificial Intelligence, vol. 40, no. 22, 2026.
- [37] W. Liu, et al., "ForceMimic: Force-centric imitation learning with force-motion capture system for contact-rich manipulation," in 2025 IEEE International Conference on Robotics and Automation, IEEE, 2025.
- [38] H. Ge, et al., "FILIC: Dual-loop force-guided imitation learning with impedance torque control for contact-rich manipulation tasks," arXiv preprint arXiv:2509.17053, 2025.
- [39] J. H. Kang, et al., "Robotic compliant object prying using diffusion policy guided by vision and force observations," IEEE Robotics and Automation Letters, 2025.
- [40] J. Li, et al., "Adaptive visuo-tactile fusion with predictive force attention for dexterous manipulation," in 2025 IEEE/RSJ International Conference on Intelligent Robots and Systems, IEEE, 2025.
- [41] Y. Hou, et al., "Adaptive compliance policy: Learning approximate compliance for diffusion guided control," in 2025 IEEE International Conference on Robotics and Automation, IEEE, 2025.
- [42] G. Lee, et al., "ManipForce: Force-guided policy learning with

frequency-aware representation for contact-rich manipulation," arXiv preprint arXiv:2509.19047, 2025.

- [43] Y. Wu, et al., "TacDiffusion: Force-domain diffusion policy for precise tactile manipulation," in 2025 IEEE International Conference on Robotics and Automation, IEEE, 2025.
- [44] R. Shukla, et al., "Force-conditioned diffusion policies for compliant sheet separation tasks in bimanual robotic cells," in 2025 IEEE International Conference on Robotics and Automation, IEEE, 2025.
- [45] Z. He, et al., "FoAR: Force-aware reactive policy for contact-rich robotic manipulation," IEEE Robotics and Automation Letters, 2025.
- [46] C. K. Verginis, D. Zelazo, and D. V. Dimarogonas, "Cooperative manipulation via internal force regulation: A rigidity theory perspective," IEEE Transactions on Control of Network Systems, vol. 10, no. 3, pp. 1222–1233, 2022.
- [47] C. K. Verginis and D. V. Dimarogonas, "Control of cooperative manipulator-endowed systems under high-level tasks and uncertain dynamics," Annual Reviews in Control, vol. 54, pp. 219–240, 2022.
- [48] B. Amos and J. Z. Kolter, "OptNet: Differentiable optimization as a layer in neural networks," in Proceedings of the 34th International Conference on Machine Learning, pp. 136–145, 2017.
- [49] Z. Xu and Y. She, "LETO: Learning constrained visuomotor policy with differentiable trajectory optimization," IEEE Transactions on Automation Science and Engineering, 2024.

- [50] W. Wan, et al., "DiffTORI: Differentiable trajectory optimization for deep reinforcement and imitation learning," *Advances in Neural Information Processing Systems*, vol. 37, pp. 109430–109459, 2024.
- [51] Z. Xu, et al., "DiffOG: Differentiable policy trajectory optimization with generalizability," *arXiv preprint arXiv:2504.13807*, 2025.
- [52] A. D. Ames, et al., "Control barrier function based quadratic programs for safety critical systems," *IEEE Transactions on Automatic Control*, vol. 62, no. 8, pp. 3861–3876, 2016.
- [53] Q. Nguyen and K. Sreenath, "Exponential control barrier functions for enforcing high relative-degree safety-critical constraints," in *2016 American Control Conference*, IEEE, 2016.
- [54] A. D. Ames, S. Coogan, M. Egerstedt, G. Notomista, K. Sreenath, and P. Tabuada, "Control Barrier Functions: Theory and Applications," 2019.
- [55] R. K. Cosner, Y. Yue, and A. D. Ames, "End-to-end imitation learning with safety guarantees using control barrier functions," in *2022 IEEE 61st Conference on Decision and Control*, IEEE, 2022.
- [56] A. Taylor, et al., "Learning for safety-critical control with control barrier functions," in *Learning for Dynamics and Control*, PMLR, 2020.
- [57] E. Todorov, T. Erez, and Y. Tassa, "MuJoCo: A physics engine for model-based control," in *2012 IEEE/RSJ International Conference on Intelligent Robots and Systems*, IEEE, 2012.
- [58] T. Yoshikawa, "Manipulability of robotic mechanisms," *The International*

Journal of Robotics Research, vol. 4, no. 2, pp. 3–9, 1985.

7. Appendix

7.1. Stage 1: Pre-training BC Policy

[Table 6] Nominal Imitation Policy (ACT) Hyper Parameters

Parameter Type	Number
Policy class	ACT
Visual backbone	ResNet-18
Input observation	4 RGB images, EE poses
State & action dimension	14
Action chunk size	50
KL weight	10
Hidden dimension	512
Feedforward dimension	3200
# of Transformer encoder layers	4
# of Transformer decoder layers	7
# of attention heads	8
Batch size	8
Policy learning rate	1.0×10^{-5}
Backbone learning rate	1.0×10^{-5}
# of training epochs	4000

7.2. Stage 2: Pre-training Delta Wrench Predictor

[Table 7] Delta Wrench Predictor Hyper Parameters

Parameter Type	Number
Observation history length	5 steps
EE pose dimension	12
Joint position dimension	12
Internal wrench dimension	6
Action dimension	12
Observation encoder hidden dimension	128
Temporal GRU hidden dimension	128
Action encoder hidden dimension	64
Prediction head hidden dimension	128
Dropout rate	0.1
Loss function	MSE + Jacobian regularization
Learning rate	1.0×10^{-4}
Weight decay	1.0×10^{-5}
Jacobian regularization weight	1.0×10^{-3}
Batch size	128
Number of training epochs	300

7.3. Stage 3: Fine-tuning Res-IL

[Table 8] Res-IL Hyper Parameters

Parameter Type	Number
Base policy learning rate	1.0×10^{-5}
Fine-tuning learning rate	2.0×10^{-6}
QP α	1.0
QP β	1.0
CBF γ	5.0
CBF slack weight	1.0×10^6
Damped pseudo-inverse coefficient	1.0×10^{-3}
Finite-difference step size	1.0×10^{-4}
Control timestep	0.02 (s)

Optimization of Imitation Learning for Internal Force Suppression in Cooperative Bimanual Manipulation

EUICHAN HEO

Department of Electrical and Electronics Engineering
The Graduate School
Pusan National University

Abstract

Recent advances in imitation learning have enabled robotic manipulation policies to learn complex manipulation behaviors from visual and proprioceptive information. In particular, Transformer-based policies have shown effective imitation of demonstration data and stable action generation in bimanual robotic manipulation. However, conventional imitation learning policies primarily focus on reproducing demonstrated trajectories and therefore do not explicitly account for the physical interaction forces that arise when two robotic arms simultaneously manipulate the same object. Under closed-chain conditions, where the two arms are coupled through a shared object, internal forces may occur. These forces do not contribute to the object's motion, but can degrade manipulation stability and increase actuator load. To address this issue, this study proposes Residual QP-based Imitation Learning (Res-IL), a framework that reduces internal forces while preserving task execution capability.

The performance of Res-IL was validated through MuJoCo-based simulation and real-world hardware experiments. In the experiments, the proposed method was compared with the conventional Action Chunking with Transformer (ACT) policy based on the wrist force/torque generated while two robotic arms grasped and lifted the same rigid object. The results show that Res-IL reduced the internal-force proxy while maintaining a task success rate

comparable to that of the baseline policy. Specifically, the proposed method reduced the average force norm and torque norm by 39.0% and 25.1%, respectively. In addition, when the Control Barrier Function (CBF) constraint was applied, the maximum force/torque magnitudes and their variance were reduced compared with the case without the CBF constraint, enabling more stable contact-rich manipulation. These results demonstrate that explicitly integrating internal-force regulation into imitation learning policies is important for physically consistent bimanual manipulation. Furthermore, the proposed residual QP structure can be extended beyond internal-force minimization to tasks requiring specific force/torque profiles, such as handle or valve rotation, thereby enabling profile-following cooperative manipulation using force information.

감사의 글

지난 2년 반에 걸친 석사 과정을 마무리하며, 부족한 저와 연구자의 길을 함께 걸어주신 많은 분께 깊은 감사의 마음을 전합니다. 소중한 인연을 맺어주신 모든 분의 앞날이 행복한 날들로 가득하기를 진심으로 기원합니다.

무엇보다 로봇에 대해 아는 것이라고는 전혀 없었던 학부생 시절부터 3년 반이 지난 지금, 한 사람의 연구자로 성장할 수 있도록 끊임없는 조언과 가르침을 주신 이인호 교수님께 진심으로 감사드립니다. 교수님께서 연구의 방향을 찾지 못하고 갈피를 잡지 못하던 순간마다 선배 연구자로서 따뜻한 위로와 공감을 건네주시며, 한 치 앞도 보이지 않는 터널 속에서도 다시 앞으로 나아갈 수 있는 힘을 주셨습니다. 또한 때로는 친구처럼 스스럼없이 사소한 고민까지 함께 나누고 진심으로 고민해 주셨습니다. 교수님의 믿음과 가르침은 제가 연구를 이어갈 수 있었던 가장 큰 힘이였으며, 앞으로의 삶에서도 오래도록 저를 올바른 방향으로 이끌어주는 소중한 이정표로 남을 것이라 생각합니다.

또한 약 2년간 학연 과정을 통해 소중한 인연을 이어가며 진심 어린 지도를 해주신 한국전자통신연구원(ETRI) 정우성 박사님께도 깊은 감사의 말씀을 드립니다. 연구를 수행하는 과정에서 마주한 여러 문제를 함께 고민해 주시고, 보다 넓은 시각에서 연구를 바라볼 수 있도록 아낌없는 조언을 건네주신 덕분에 연구자로서 한층 더 성장할

수 있었습니다. 연구에 대한 진지한 태도와 책임감, 그리고 문제를 끝까지 해결하고자 하는 자세를 몸소 보여주신 박사님의 가르침은 앞으로 연구자의 길을 걸어가는 데 있어 소중한 자산이 될 것입니다.

지난 3년 반 동안 회로애락을 함께해 온 CAMEL 연구실의 선배님, 동기, 후배 여러분께도 감사의 마음을 전합니다. 어둠이 짙게 내려앉은 늦은 밤에도 연구실의 불을 밝히며 함께 고민하고, 끊이지 않는 대화와 웃음 속에서 힘든 시간을 이겨냈던 순간들을 잊지 못할 것입니다. 반복되는 실험과 수많은 실패 속에서도 서로를 격려하며 앞으로 나아갔고, 비록 작은 성공일지라도 함께 기뻐했던 기억들은 제게 무엇과도 바꿀 수 없는 소중한 추억으로 남았습니다. 여러분과 함께 고민하고 성장했던 시간은 앞으로 마주하게 될 여러 어려움을 조금 더 지혜롭고 유연하게 견뎌낼 수 있는 원동력이 될 것입니다. 함께한 모든 분의 앞날에 값진 결실과 행복이 가득하기를 진심으로 바랍니다.

마지막으로 언제나 저를 믿고 지지해 준 사랑하는 가족들에게 깊은 감사의 마음을 전합니다. 특히 지금은 하늘의 별이 되셨지만, 제가 선택한 길을 의심하지 말고 씩씩하게 걸어가라고 말씀해 주셨던 어머니께 진심으로 감사드립니다. 늘 한결같은 자리에서 묵묵히 저의 길을 응원해 주시고, 수많은 굴곡과 어려움을 마주할 때마다 제 곁을 지켜주신 가족의 헌신과 사랑이 있었기에 이 모든 과정을 끝까지 이겨낼 수 있었습니다. 말로는 다 표현할 수 없는 감사와 사랑의 마음을 이 글을 통해 전하고 싶습니다.

니다.

앞으로의 여정에서 다음 경유지가 어디가 될지는 아직 알 수 없습니다. 그러나 수많은 고민과 해결이 반복되는 연구자의 길 위에서 현재의 모습에 안주하지 않고 끊임 없이 앞으로 나아가겠습니다. 동시에 목적지만을 바라보느라 곁에 있는 소중한 인연들을 놓치지 않으며, 함께 걷는 사람들의 마음을 살피고 감사할 줄 아는 사람이 되겠습니다. 지금까지 받은 믿음과 사랑을 잊지 않고, 언젠가는 저 또한 누군가에게 힘이 되고 길을 밝혀줄 수 있는 연구자로 성장하겠습니다.

다시 한번, 지금의 제가 있기까지 함께해 주신 모든 분께 진심으로 감사드립니다.